



UNIVERSIDAD
DE LA REPUBLICA
URUGUAY

Análisis Del Impacto De Política Monetaria

Comparación De Modelos De Factores Dinámicos

Laura Marta Montaldo Iglesias

Programa de Posgrado en Ingeniería Matemática
Facultad de Ingeniería
Universidad de la República

Montevideo – Uruguay
Diciembre de 2023



UNIVERSIDAD
DE LA REPUBLICA
URUGUAY

Análisis Del Impacto De Política Monetaria

Comparación De Modelos De Factores Dinámicos

Laura Marta Montaldo Iglesias

Tesis de Maestría presentada al Programa de Posgrado en Ingeniería Matemática, Facultad de Ingeniería de la Universidad de la República, como parte de los requisitos necesarios para la obtención del título de Magíster en Ingeniería Matemática.

Director:

Ph.D. Prof. Marco Scavino

Director académico:

Ph.D. Prof. Paola Bermolen

Montevideo – Uruguay

Diciembre de 2023

Montaldo Iglesias, Laura Marta

Análisis Del Impacto De Política Monetaria / Laura Marta Montaldo Iglesias. - Montevideo: Universidad de la República, Facultad de Ingeniería, 2023.

xv, 99 p.: il.; 29, 7cm.

Director:

Marco Scavino

Director académico:

Paola Bermolen

Tesis de Maestría – Universidad de la República, Programa en Ingeniería Matemática, 2023.

Referencias bibliográficas: p. 58 – 60.

1. Modelos de Factores dinámicos,
2. Modelos de Vectores Autorregresivos Aumentados Por Factores,
3. Modelo de Factores Dinámicos Profundo,
4. Política Monetaria,
5. Funciones de respuesta al impulso,
6. Descomposición De La varianza Del Error De Predicción,
7. Dynamic Factor Models,
8. Factor-Augmented Vector Autoregressive Models,
9. Deep Dynamic Factor Model,
10. Monetary Policy,
11. Impulse Response Functions,
12. Forecast Error Variance Decomposition. I. Scavino, Marco, . II. Universidad de la República, Programa de Posgrado en Ingeniería Matemática. III. Título.

INTEGRANTES DEL TRIBUNAL DE DEFENSA DE TESIS

D.Sc. Prof. Nombre del 1er Examinador Apellido

Ph.D. Prof. Nombre del 2do Examinador Apellido

D.Sc. Prof. Nombre del 3er Examinador Apellido

Ph.D. Prof. Nombre del 4to Examinador Apellido

Ph.D. Prof. Nombre del 5to Examinador Apellido

Montevideo – Uruguay

Diciembre de 2023

Dedico esta tesis a mi padre que
fue el primero que con amor,
paciencia y buena voluntad me
supo explicar matemática.

Agradecimientos

Quisiera agradecer, en un primer momento, a Elizabeth Bucacos que me introdujo a los modelos FAVAR y me dió la dirección para la creación de esta tesis, a Marco Scavino por su paciencia infinita, por presentarme el mundo de los modelos dinámicos de factores y por ser mi tutor. También a Paola Bermolen por ayudarme en todo este proceso y a la Facultad de Ingeniería por darme la oportunidad de cursar la Maestría en Ingeniería Matemática.

*Una teoría económica es una
abstracción del mundo real.
Entre otras razones, la inmensa
complejidad de la realidad
económica hace imposible
comprender todas las
interrelaciones a un tiempo;
tampoco tienen todas ellas igual
importancia en lo que atañe a
los fenómenos económicos que
estudiamos. Por eso, lo más
sensato es elegir los que, a
nuestro juicio, constituyen los
factores y relaciones
primordiales que interesan a
nuestro problema, y concentrar
la atención exclusivamente en
ellos. Un esquema analítico de
esta índole, deliberadamente
simplificado, se llama modelo
económico, pues representa la
realidad económica de una
manera esquemática y
aproximada.*

Alpha Chiang

RESUMEN

Esta tesis presenta una exploración detallada del impacto de las políticas monetarias contractivas a través del prisma de modelos de factores dinámicos. Profundizando en el análisis, se parte con un modelo FAVAR que sirve de punto de referencia, se compara con otro lineal estimado por el algoritmo de Esperanza-Maximización y posteriormente se introduce un modelo no lineal. El núcleo innovador de este trabajo reside en la comparación de estos modelos lineales tradicionales con una propuesta vanguardista: el modelo *Deep Dynamic Factor Model*, un paradigma emergente en el aprendizaje profundo. Comparando los resultados para distintas cantidades de factores, esta investigación no solo arroja luz sobre el rendimiento predictivo de estos modelos, sino que también ofrece una perspectiva única sobre las consecuencias de las políticas monetarias en variables económicas seleccionadas. Además, este estudio abre el debate sobre si incorporar modelos de aprendizaje profundo en los estudios de política monetaria, dado que emplear modelos de cajas negras podría tener consecuencias negativas en temas sensibles como es la política económica. Por tanto, esta investigación contribuye a la literatura existente con un análisis comparativo robusto y introduce una herramienta analítica sofisticada para la interpretación de políticas monetarias en un entorno económico complejo. Palabras claves:

Modelos de Factores dinámicos, Modelos de Vectores Autorregresivos Aumentados Por Factores, Modelo de Factores Dinámicos Profundo, Política Monetaria, Funciones de respuesta al impulso, Descomposición De La varianza Del Error De Predicción, Dynamic Factor Models, Factor-Augmented Vector Autoregressive Models, Deep Dynamic Factor Model, Monetary Policy, Impulse Response Functions, Forecast Error Variance Decomposition.

ABSTRACT

This thesis presents a detailed exploration of the impact of contractionary monetary policies through the lens of dynamic factor models. Delving deeper into the analysis, it starts with a FAVAR model that serves as a reference point, is compared with another linear model estimated by the Expectation-Maximization algorithm, and then introduces a nonlinear model. The innovative core of this work lies in the comparison of these traditional linear models with a cutting-edge proposal: the 'Deep Dynamic Factor Model', an emerging paradigm in deep learning. By comparing the results for different numbers of factors, this research not only sheds light on the predictive performance of these models but also offers a unique perspective on the consequences of monetary policies on selected economic variables. Furthermore, this study opens the debate on whether to incorporate deep learning models into monetary policy studies, as using black-box models could have negative consequences in sensitive areas such as economic policy. Therefore, this research contributes to the existing literature with a robust comparative analysis and introduces a sophisticated analytical tool for interpreting monetary policies in a complex economic environment. Keyword:

Lista de figuras

2.1	Representación del proceso de entrenamiento del modelo D^2FM	16
3.1	Scree plot de los valores propios ordenados	28
3.2	Criterios de informacion	29
3.3	Scree plot de la varianza explicada acumulada	30
3.4	Predicciones 145 pasos hacia adelante para distinta cantidad de factores	31
3.5	Características y elecciones en el modelo	34
5.1	Funciones de respuesta al impulso en FAVAR	46
5.2	Funciones de respuesta al impulso en DFM estimado por algoritmo EM	47
5.3	Funciones de respuesta al impulso en D^2FM	48
1.1	Esquema de implementación general	99

Lista de tablas

3.1	Cantidad de series estacionarias y no estacionarias	25
4.1	Métricas promedio de desempeño para cada modelo con DFM .	39
4.2	Métricas promedio de desempeño para cada modelo con FAVAR	39
4.3	Métricas promedio de desempeño para cada modelo con D^2FM	40
5.1	Variables para análisis de impacto de PL	45
5.2	DV para FAVAR	51
5.3	DV para DFM con algoritmo EM	53
5.4	DV para D^2FM	54
1.1	Conjunto de datos I	63
1.2	Conjunto de datos II	64
1.3	Conjunto de datos III	65
1.4	Conjunto de datos IV	66
3.1	Modelos del test ADF	74
3.2	Resultados de las pruebas ADF: modelo ct	79
3.3	Resultados de las pruebas ADF: modelo c	80
3.4	Resultados de las pruebas ADF: modelo n	81
3.5	Resultados de las pruebas KPSS	83
3.6	Series en el mejor modelo KPSS	84
5.1	Consumo, órdenes e inventarios	90
5.2	Vivienda	90
5.3	Intereses y tipos de cambio	91
5.4	Mercado de trabajo	92
5.5	Producto e ingresos	93
5.6	Producto e ingresos	93

5.7	Dinero y crédito	94
5.8	Mercado de activos	94
6.1	Variables para análisis de impacto de Política Monetaria (PM) .	96

Tabla de contenidos

Lista de figuras	X
Lista de tablas	XI
Lista de símbolos	XII
Notaciones	XII
1 Introducción	1
1.1 Motivación y objetivos	2
2 Fundamentos teóricos	5
2.1 Modelos de factores dinámicos lineales	6
2.2 Modelo de factores dinámicos profundo	13
3 Estrategia empírica	19
3.1 Esquema de implementación	20
3.2 Datos del estudio	21
3.2.1 Fuente del conjunto de datos a emplear	21
3.2.2 Preprocesamiento de las series de tiempo	22
3.3 Implementación de los DFM lineales	28
3.3.1 Determinación de la cantidad óptima de factores	28
3.3.2 Implementación del DFM con Algoritmo EM	31
3.3.3 Implementación del modelo FAVAR	32
3.4 Implementación del modelo no lineal	34
3.4.1 Implementación del modelo D^2FM	34
4 Evaluación de los modelos	37
4.1 Métricas de desempeño predictivo	38

4.2	Resultados para el DFM estimado con algoritmo EM	39
4.3	Resultados para el modelo FAVAR	39
4.4	Resultados para el modelo D^2FM	40
5	Análisis de impacto de política monetaria	41
5.1	Definición de la política monetaria	42
5.2	Funciones de respuesta al impulso y descomposición de la varianza	43
6	Consideraciones finales	55
6.1	Conclusiones	56
	Referencias bibliográficas	58
	Glosario	60
	Apéndices	61
	Apéndice 1 Conjunto de datos	62
1.1	Nombre de cada variable, su tcode, descripción y agrupación . .	63
1.2	Códigos de transformación de las series de datos	67
	Apéndice 2 Modelos VAR	68
2.1	Modelos VAR y SVAR	69
2.2	Funciones de respuesta al impulso y Descomposición de la va- rianza del error de predicción	71
	Apéndice 3 Estacionariedad de la series temporales	72
3.1	Concepto de series de tiempo estacionarias	73
3.2	Pruebas ADF	73
3.3	Pruebas KPSS	76
3.4	Resultados de las pruebas ADF y KPSS	78
3.4.1	Resultados de las pruebas ADF	78
3.4.2	Resultados de las pruebas KPSS	82
	Apéndice 4 DFM estático	85
4.1	Algoritmo ME	86
	Apéndice 5 FAVAR	89
5.1	Variables macroeconómicas lentas y rápidas	90
	Apéndice 6 Análisis de FIR y ED	95
6.1	Variables macroeconómicas para el análisis de impacto de políti- ca monetaria	96

Anexos	97
Anexo 1 Esquema de implementación	98
1.1 Esquema de implementación en Python y R	99

Capítulo 1

Introducción

1.1. Motivación y objetivos

El presente estudio se ubica en lo que Bernanke y Boivin (2003), denominaron *entorno rico en datos*, caracterizado por la disponibilidad de un amplio conjunto de variables y observaciones temporales. Esta idea contrasta con la tendencia general en la literatura, donde comúnmente se utiliza un número limitado de variables para analizar los efectos de ciertas perturbaciones sobre la economía. Sin embargo, en la práctica, los bancos centrales suelen seguir y monitorear una vasta cantidad de datos para determinar las dinámicas de un sistema económico. Un ejemplo de lo anterior son los estudios y publicaciones de Michael W. McCracken con series temporales económicas mensuales y trimestrales para la Reserva Federal de Estados Unidos.

La literatura dominante se ha limitado a enfoques en los que se asume que los bancos centrales explotan una cantidad restringida de información. En estas circunstancias, se destaca el uso de los modelos de Vectores Autorregresivos (VAR)¹ para caracterizar los determinantes y efectos de la política monetaria sobre lo que se podría conceptualizar como *la economía*. Sin embargo, este tipo de modelos padecen lo que se conoce en la literatura como *la maldición de la dimensionalidad*, lo que limita su eficacia para manejar grandes volúmenes de datos y reflejar adecuadamente la complejidad de la economía moderna. Aunque los modelos VAR son apreciados por su simplicidad, surge una discrepancia notable entre la amplia gama de series temporales que los bancos centrales monitorean y analizan, y la capacidad limitada de estos modelos para capturar y medir los efectos de una perturbación en una variable considerada exógena sobre otras variables macroeconómicas. En este contexto, han surgido otros enfoques que permiten incorporar información adicional, y uno de los más destacados es el modelo Vectores Autorregresivos Aumentado Por Factores (FAVAR)². Este enfoque fue propuesto inicialmente por Bernanke et al. (2005) como una herramienta para abordar el problema de la gran dimensionalidad de los datos económicos. Desde su introducción, el mencionado modelo se ha establecido como un enfoque esencial en la modelización macroeconómica. Ha encontrado aplicación en una variedad de estudios, abarcando desde la evaluación de políticas económicas hasta el análisis de los impactos de perturbaciones financieras en la economía.

¹Por sus siglas en inglés relativas a Vector Autoregressive models

²Por sus siglas en inglés relativas a Factor-Augmented Vector Autoregression

El modelo FAVAR es una extensión del VAR y se basa en la idea de que múltiples series temporales macroeconómicas pueden ser influenciadas por factores comunes inobservables, también conocidos como factores latentes.

Siguiendo a Bernanke et al. (2005), estos factores son constructos no directamente medibles como puede ser la *actividad económica*, *condiciones crediticias*, *tendencias generales de la economía* y no sería posible representarlos por una o pocas series temporales. Como consecuencia, la inclusión de estos factores en el análisis mejoraría significativamente la capacidad de pronóstico y comprensión de la economía, al capturar la riqueza de datos de numerosas series temporales, como señalan investigaciones de Stock y Watson.

Como referencia local, Bucacos (2015) analiza el impacto de la política monetaria internacional sobre variables relevantes para la economía uruguaya empleando el mencionado enfoque FAVAR. Este estudio sirve para entender los canales de transmisión de perturbaciones externas sobre una economía pequeña, abierta y dolarizada. En particular, estima los factores empleando un método por máxima verosimilitud y se plantean distintos esquemas de identificación tanto recursivo como no recursivo. En este estudio es novedoso en el sentido de que fue la primera vez que se empleó el enfoque FAVAR para el caso de la economía uruguaya, constituyendo un punto de partida para posteriores análisis. A su vez, como referencia internacional, Stock y Watson (2016) analizan los efectos de las perturbaciones de oferta del petróleo sobre un gran conjunto de series de datos para la economía de Estados Unidos. Este caso sirve de base para entender que las aplicaciones del modelo FAVAR son múltiples y no sólo se limitan a los efectos de los shocks de política monetaria sobre otras variables económicas.

Los modelos FAVAR son un caso particular de los modelos Modelos de Factores Dinámicos (DFM)¹, situándose en el contexto teórico de estados latentes lineales.

En el presente trabajo de investigación, se adopta la metodología propuesta por Stock y Watson relativa a esquemas de reducción de la dimensionalidad para evaluar cómo las perturbaciones de política monetaria afectan a un grupo de variables económicas que representan *la economía*. De esta manera, se tiene como objetivo analizar y cuantificar el impacto de las variaciones en la tasa de interés de referencia de la Reserva Federal de Estados Unidos sobre un amplio conjunto de series temporales. Para ello, se utiliza como base la representación

¹Por sus siglas en inglés relativas a Dynamic Factor Models

de un DFM estático, propuesto por Stock y Watson (2016) y se toma como punto de referencia los resultados de un modelo FAVAR.

Reconociendo que existen múltiples enfoques para la estimación de factores latentes, se procederá también a estimarlos utilizando la metodología propuesta por Banbura y Modugno (2014).

Además, como innovación en este estudio, se realiza una comparación entre los resultados obtenidos con los mencionados modelos lineales y aquellos derivados de un modelo dinámico de factores profundo (D^2FM), propuesto por Andreini et al. (2023b). Los autores ofrecen una alternativa a los modelos dinámicos de factores tradicionales, incorporando una estructura no lineal, que a nivel computacional podría ser más eficiente cuando se aumenta la cantidad de variables. El modelo D^2FM constituye una generalización de los modelos dinámicos de factores en un esquema de aprendizaje profundo. Este modelo facilita la inclusión de no linealidades entre los factores y las variables observables, gracias a su estructura de red neuronal profunda. Una ventaja de este modelo es que, a pesar de su complejidad, sus resultados serían comparables con los de un modelo lineal como el FAVAR, manteniendo un nivel similar de flexibilidad e interpretabilidad.

Considerando lo expuesto anteriormente, un objetivo primario de esta investigación es evaluar y comparar el rendimiento predictivo de diversos modelos al aplicar diferentes técnicas para estimar factores inobservables. Posteriormente, tras la estimación de estos factores mediante los distintos métodos, se emplea un modelo VAR para examinar las funciones de impulso-respuesta y la descomposición de la varianza, particularmente en el contexto de una política monetaria contractiva. En este sentido, se busca analizar el impacto de un incremento en la tasa de interés de referencia sobre un grupo seleccionado de variables económicas relevantes.

Capítulo 2

Fundamentos teóricos

2.1. Modelos de factores dinámicos lineales

El presente análisis se enmarca en lo que Stock y Watson (2016) definen como DFM. El supuesto fundamental en este tipo de modelos se basa en que la dinámica común de un gran conjunto de series económicas se asocia a un conjunto significativamente menor de factores latentes e inobservables. Este tipo de modelos son un caso particular de los modelos de espacio de estado o modelos de markov ocultos, para los cuales ciertas variables observables se expresan en términos de variables latentes inobservables que evolucionan de acuerdo a una dinámica rezagada con dependencia finita. De esta manera, se pueden resumir los complejos movimientos de un número potencialmente grande de series observables en un número menor de factores que conducen las fluctuaciones comunes de *la economía*.

Los DFM se pueden expresar tanto en términos dinámicos como estáticos, lo que conlleva a dos métodos de estimación distintos. Para el caso dinámico se va a representar la dependencia de las series temporales X_t en los rezagos de los factores de manera explícita, mientras que para el caso estático, dicha representación es implícita. En ambos casos, se asume que tanto las variables observables como latentes son estacionarias de segundo orden e integradas de orden cero.

Los DFM en su forma dinámica, se definen como un vector X_t de series temporales observables de tamaño $N \times 1$ que dependen de un número menor de factores latentes e inobservables f_t de tamaño q y de un componente idiosincrático e_t con media cero¹.

El DFM dinámico se representa como

$$X_t = \lambda(L)f_t + e_t, \quad (2.1)$$

$$f_t = \Psi(L)f_{t-1} + \eta_t \quad (2.2)$$

donde la matrices de rezagos polinomiales $\lambda(L)$ y $\Psi(L)$ son de tamaño $N \times q$ y $q \times q$, respectivamente, mientras que η_t es el vector de innovaciones de tamaño $q \times 1$, con media cero, serialmente incorrelacionado con los factores.

Se asume que las perturbaciones idiosincráticas están incorrelacionadas con

¹En general, los factores latentes y el término idiosincrático van a estar serialmente correlacionados.

el vector de innovaciones en todos sus rezagos, esto es, $Ee_t\eta'_{t-k} = 0$ para todo k . Además, en general, e_t puede estar serialmente correlacionado².

Por su parte, en el DFM estático o apilado la forma dinámica (2.1) y (2.2) depende de $r \geq q$ factores estáticos F_t , en vez de q factores dinámicos f_t .

El DFM en su forma estática se representa como

$$X_t = \Lambda F_t + e_t, \quad (2.3)$$

$$F_t = \Phi(L)F_{t-1} + G\eta_t \quad (2.4)$$

donde $F_t = (f'_t, f'_{t-1}, \dots, f'_{t-p})'$ es el vector de factores estáticos de tamaño $r \times 1$, $\Lambda = (\lambda_0, \lambda_1, \dots, \lambda_p)$, p los grados de la matriz de rezagos polinomial $\lambda(L)$, $\Phi(L)$ es una matriz de unos, ceros con los elementos de $\Psi(L)$ y $G = [I_q \quad 0_{q \times (r-q)}]'$.

En este esquema, la estimación de los factores se puede realizar mediante un enfoque no paramétrico en dos pasos por Componentes Principales (PC)¹, que resuelven el problema de mínimos cuadrados para los cuales Λ y F son parámetros desconocidos a estimar:

$$\min_{F_1, \dots, F_T, \Lambda} V_r(\Lambda, F) = \frac{1}{NT} \sum_{t=1}^T (X_t - \Lambda F_t)^T (X_t - \Lambda F_t) \quad (2.5)$$

s.a normalización

La normalización puede ser $N^{-1}\Lambda\Lambda = I$ con Σ_F diagonal y $\Sigma_F = E(F_t^T F_t)$ o $F_t F_t^T / T = I$ cuando se retringen los factores.

Otra alternativa de estimación es la que se emplea en Banbura y Modugno (2014) con el algoritmo Maximización de la Esperanza (EM)². Los detalles del mismo se encuentran en el Apéndice 4.1.

²Cuando las perturbaciones idiosincrásicas e_t en (2.1) estén serialmente incorrelacionadas, los modelos (2.1) y (2.2) van a estar completamente especificados.

¹Por sus siglas en inglés relativas a Principal Components.

²Por sus siglas en inglés relativas a Expectation Maximisation.

Ahora, partiendo de un DFM en su forma estática, cuando además se asume que las innovaciones son una combinación lineal de unas perturbaciones estructurales inobservables tales que

$$\eta_t = H\varepsilon_t, \quad (2.6)$$

Y las perturbaciones estructurales están incorrelacionadas

$$E\varepsilon_t\varepsilon_t' = \Sigma_\varepsilon = \begin{bmatrix} \sigma_{\varepsilon_1}^2 & & 0 \\ & \ddots & \\ 0 & & \sigma_{\varepsilon_n}^2 \end{bmatrix}$$

se está en el marco de un Modelos de Factores Dinámicos Estructurales (SDFM)¹ y se expresa como

$$\overset{n \times 1}{X_t} = \overset{n \times rr \times 1}{\Lambda} \overset{r \times 1}{F_t} + \overset{n \times 1}{e_t}, \quad (2.7)$$

$$\overset{r \times r}{\Phi(L)} \overset{r \times 1}{F_t} = \overset{r \times q}{G} \overset{q \times 1}{\eta_t} \quad \text{donde } \Phi(L) = I - \Phi_1 L - \dots - \Phi_p L^p \quad (2.8)$$

$$\overset{q \times 1}{\eta_t} = \overset{q \times q}{H} \overset{q \times 1}{\varepsilon_t} \quad (2.9)$$

En este sistema, las q perturbaciones estructurales ε_t impactan en los factores comunes pero no así al término idiosincrático. Bajo este esquema, todos los factores son inobservables. Sin embargo, cuando alguno de los factores se considera observable, el SDFM se transforma en un FAVAR.

¹Por sus siglas en inglés relativas a Structural Dynamic Factor Models.

En los modelos FAVAR algunos factores van a ser observados mientras que el resto sigue siendo latente. Como consecuencia, se imponen restricciones adicionales dado que al menos un factor va a estar medido sin error por al menos una variable observable. Una representación típica de éstos modelos es la introducida por Bernanke et al. (2005), donde Y_t es el vector de tamaño $M \times 1$ variables observables que conducen la dinámica de la economía y los factores inobservados F_t son de tamaño $r \times 1$ donde r es pequeño. De esta manera, la dinámica conjunta de (F_t', Y_t') se puede representar por la *ecuación de transición*.

$$\begin{bmatrix} F_t \\ Y_t \end{bmatrix} = \Phi(L) \begin{bmatrix} F_{t-1} \\ Y_{t-1} \end{bmatrix} + v_t, \quad (2.10)$$

donde $\Phi(L)$ es el polinomio de rezagos conformable finito de orden d . El término de error v_t tiene media cero con matriz de covarianzas Q .

La ecuación (2.10) es un VAR en (F_t', Y_t') . Cuando los términos de $\Phi(L)$ sean iguales a cero se obtiene un VAR de Y_t en su forma estándar. Para más detalles sobre los modelos VAR ver Apéndice 2.1.

En este marco, se supone que se cuenta con un conjunto N de series informacionales X_t , siendo N grande¹ y mucho mayor a la cantidad de factores y variables observables en el sistema ($r + M \ll N$).

A su vez, las series de tiempo informacionales X_t se relacionan a F_t y Y_t mediante una *ecuación de observación* bajo la forma

$$X_t = \Lambda^f F_t + \Lambda^y Y_t + e_t \quad (2.11)$$

donde Λ^f es la matriz de pesos de los factores de tamaño $r \times N$, Λ^y es de tamaño $N \times M$ y el vector de errores e_t es de tamaño $N \times 1$ con media cero. La ecuación (2.11) captura la idea de que tanto Y_t como F_t ² representan a los factores comunes que conducen la dinámica de *la economía* X_t ³.

Como los factores son inobservables, para que se pueda estimar el modelo se tienen que imponer restricciones sobre (2.10)-(2.11). Esto implica hacer a identificación del sistema. Dado que en (2.10) la dinámica se deja irrestricta, es necesario imponer restricciones sobre los factores y los coeficientes de la

¹En particular, $N > T$ con T siendo la cantidad de períodos.

² Y_t y F_t , en general, pueden estar correlacionados

³Cuando en la ecuación (2.11) no se tengan factores observables el modelo es un DFM en su forma estática.

ecuación (2.11). Si se asume que $\hat{\Lambda}^f$ y \hat{F}_t son una solución al problema de estimación (2.5), se puede definir $\tilde{\Lambda}^f = \hat{\Lambda}^f H$ y $\tilde{F}_t = H^{-1} \hat{F}_t$ donde H es una matriz no singular de tamaño $N \times N$. Además, se tiene que imponer una normalización⁴.

En el enfoque por CP se emplea un método en dos pasos para descubrir el espacio abarcado por los componentes comunes $C_t = (F'_t, Y'_t)$ en (2.11). En este sentido, en una primera etapa, la estimación de C_t se realiza empleando los $r + M$ componentes principales de X_t . Como consecuencia, \hat{F}_t sería la parte del espacio cubierto en \hat{C}_t que no fue cubierta por Y_t . En una segunda etapa, se estima la ecuación (2.10) con métodos estándares, reemplazando a F_t por su estimación \hat{F}_t .

La estimación mediante el método de PC presenta la ventaja de ser un procedimiento sencillo y fácil de implementar, ya que no requiere de supuestos estrictos sobre las distribuciones y tolera cierto nivel de correlación cruzada en el término e_t . No obstante, una desventaja significativa de este método es que conlleva la generación de regresores en la segunda etapa del proceso de estimación.

Con respecto a la normalización del sistema, se pueden restringir a los pesos $\Lambda^f \Lambda^f / N = I$ o a los factores $F'F/T = I$. En este estudio se impone el segundo caso, obteniendo $\hat{F} = \sqrt{T} \hat{Z}$ donde \hat{Z} son los vectores propios asociados a los r mayores valores propios en XX' , ordenados de manera descendiente.

Los modelos FAVAR se han empleado en la literatura para analizar los impactos de las políticas monetarias sobre la economía. A diferencia de los modelos VAR, los primeros permiten superar el problema de la maldición de la dimensionalidad (ver Bellman (1957)) presente en los VAR. Una de las ventajas del FAVAR frente al VAR es que, un vez estimado el sistema se puede usar para trazar las respuestas dinámicas no solo de algunas variables importantes Y_t sino que de cualquier variable contenida en X_t . Además, se pueden calcular las funciones de impulso-respuesta de los factores¹.

Dos objetivos en este tipo de análisis son la estimación de las Funciones Impulso-Respuesta Estructurales (SIRF)² y de la Descomposición De La Varianza Del Error de Predicción (FEVD)³. Ambas se obtienen a partir de la

⁴Para el caso de la estimación por CP, en el primer paso, se puede emplear la normalización implícita en la misma.

¹Cuando se los considera en un concepto amplio como *la actividad económica*

²Por sus siglas en inglés relativas a Structural impulse-response Functions

³Por sus siglas en inglés Forecast Error Variance Decomposition

representación Medias Móviles (MA)⁴ del VAR del sistema y a partir de la varianza de las perturbaciones estructurales (ver Apéndice 2.1). Las funciones de respuesta al impulso describen cómo las variables de un sistema económico reaccionan a lo largo del tiempo a un choque en una de las variables. Con esto se busca analizar cómo un choque en uno de los factores afecta a las series temporales observadas, a lo largo de diferentes horizontes temporales. Por su parte, la descomposición de la varianza del error de predicción ayuda a identificar qué proporción del error total en la predicción de una variable puede atribuirse a las fluctuaciones en cada una de las otras variables del modelo.

⁴Por sus siglas en inglés Moving Averages

En una segunda etapa del estudio, se van a comparar los resultados de un modelo FAVAR con un DFM estático como el empleado en Banbura y Modugno (2014). Se define $y_t = [y_{1,t}, y_{2,t}, \dots, y_{n,t}]'$, $t = 1, \dots, T$ el vector de tamaño n estandarizado con media cero y varianza unitaria. Entonces y_t se puede representar como

$$y_t = \Lambda f_t + \epsilon_t \quad (2.12)$$

donde f_t son los factores comunes de tamaño $r \times 1$ y ϵ_t es componente idiosincrático incorrelacionado con f_t .

Por su parte, los componentes comunes f_t siguen un proceso VAR estacionario de orden p :

$$f_t = A_1 f_{t-1} + A_2 f_{t-2} + \dots + A_p f_{t-p} + u_t, \quad u_t \stackrel{iid}{\sim} N(0, Q). \quad (2.13)$$

donde A_1, A_2, \dots, A_p es la matriz de coeficientes autorregresivos de tamaño $r \times r$.

Se asume un proceso $VAR(2)$ para los factores y un $VAR(1)$ para el componente idiosincrático. Dado que una estimación por máxima verosimilitud en general puede no ser factible, los autores proponen adoptar el algoritmo EM.

Los detalles del método de estimación por el algoritmo EM se detallan en el Apéndice 4.1 y se resumen en el presente pseudo código 1.

Algorithm 1 Algoritmo EM para maximización de log-verosimilitud

Inicializar $\theta(0)$ con valores estimados

while no se logra la convergencia **do**

Paso de Expectativa:

 Calcular la log-verosimilitud condicional:

$$L(\theta, \theta(j)) = \mathbb{E}_{\theta(j)}[l(Y, F; \theta) | \Omega_T]$$

Paso de Maximización:

 Estimar los parámetros maximizando la log-verosimilitud:

$$\theta(j+1) = \underset{\theta}{\operatorname{argmax}} L(\theta, \theta(j))$$

 Actualizar Λ, A, R, Q usando las fórmulas dadas

end while

return θ

2.2. Modelo de factores dinámicos profundo

Desde la perspectiva del aprendizaje profundo, los modelos anteriores podrían presentar ciertas debilidades porque asumen una estructura lineal y porque pueden enfrentar problemas de escalabilidad computacional cuando se manejan muchas variables. Por tanto, sería útil comparar los resultados de los DFM lineales con aquellos basados en aprendizaje profundo para evaluar si pueden superar dichas limitaciones, manteniendo al mismo tiempo su flexibilidad e interpretabilidad. En este sentido, en una tercera etapa de este estudio, se va a estimar el Modelo de Factores Dinámicos Profundo (D^2FM)¹ propuesto por Andreini et al. (2023b), siguiendo el método de estimación de los parámetros en dos pasos propuesto por los autores.

El D^2FM emplea Codificadores Automáticos (AE)². Son redes neuronales entrenadas para mapear un conjunto de variables en sí mismas. Se codifica primero la entrada en una representación de dimensiones inferiores y luego se decodifica nuevamente en sí misma. De esta manera, la representación en baja dimensión fuerza al AE a capturar las características más importantes de los datos. Es por esto que los AE pueden considerarse como una generalización no lineal de CP.

Se parte de una formulación general de modelos de factores latentes con características idiosincrásicas. Se define $\mathbf{y}_t = (y_{t,1}, \dots, y_{t,n})$ como el vector que recoge las n variables de interés en el momento t . Entonces, un modelo de factores latentes general se puede expresar como

$$\mathbf{y}_t = F(\mathbf{f}_t) + \varepsilon_t = \tilde{\mathbf{y}}_t + \varepsilon_t, \quad (2.14)$$

donde \mathbf{f}_t es un vector de componentes comunes estocásticos, de tamaño $r \times 1$, con $r = \dim(\mathbf{f}) \ll \dim(\mathbf{y})$. Por su parte, ε_t es el término de perturbaciones estocásticas y $F(\cdot)$ es una función genérica que mapea a los factores inobservados en las variables observables. Se asume que \mathbf{f}_t y ε_t son independientes, con media cero y varianza finita. Por su parte, $\tilde{\mathbf{y}}_t$ es el componente de \mathbf{y}_t que se relaciona con los factores comunes³. Cuando $F(\cdot)$ no sea lineal, se puede expresar al componente de factores como

¹En inglés: Deep Dynamic Factor Models

²Por sus siglas en inglés relativas a AutoEncoders.

³Cuando se asuma que $F(\cdot)$ es una función lineal, el modelo se reduce a un modelo de factores lineal estándar.

$$\tilde{\mathbf{y}}_t = F(G(\mathbf{y}_t)) = (F \circ G)(\mathbf{y}_t) = (F \circ G)(\tilde{\mathbf{y}}_t + \boldsymbol{\varepsilon}_t) \quad (2.15)$$

donde $G(\cdot)$ es la función que mapea a las observables en el código \mathbf{f}_t , o sea, la función de *encoding* y $F(\cdot)$ es la función que mapea de vuelta a los factores en \mathbf{y}_t , esto es, la función de *decoding*.

Los AE resuelven el problema paramétrico de encontrar un mapeo¹ de la forma $\tilde{\mathbf{y}}_t = F(G(\mathbf{y}_t))$ bajo la restricción de minimizar una función de pérdida tal que

$$\mathcal{L}(\mathbf{y}_t, \tilde{\mathbf{y}}_t; \boldsymbol{\theta}) = \mathcal{L}(\mathbf{y}_t, F(G(\mathbf{y}_t))), \quad (2.16)$$

donde $\mathcal{L}(\cdot)$ es la función de pérdida y $\boldsymbol{\theta}$ es el vector que contiene todos los parámetros en $G(\cdot)$ y $F(\cdot)$. En este sentido, el análisis de CP se puede interpretar como un AE que minimiza una función de pérdida cuadrada tal que

$$\mathcal{L}(\mathbf{y}_t, \tilde{\mathbf{y}}_t; \boldsymbol{\theta}) = \|\mathbf{y}_t - \tilde{\mathbf{y}}_t\|^2 \quad (2.17)$$

Como en principio $G(\cdot)$ y $F(\cdot)$ pueden ser cualquier función no lineal, encontrar una forma funcional que recoja el proceso generativo de los datos podría ser un problema en sí mismo. Los AE brindan una implementación práctica para este problema al expresar la composición de dos funciones como una cadena de Perceptrones Multicapa (MLP). En la primer cadena, opera el *encoding* mientras que en la segunda, se produce la salida de *decoding*.

Un MLP es un tipo de red neuronal artificial *feedforward* compuesta por varias capas *ocultas*. Cada una está conformada por un conjunto de *neuronas*². Cada neurona en cada capa recibe ciertas entradas de las neuronas de la capa anterior y devuelve, para la siguiente capa, una salida de activación (h_{ml}^l).

La función de activación³ de cada neurona es una función no lineal parametrizada que se expresa como

$$h_{ml}^l = g_{ml}^l (\mathbf{W}_{ml}^l h^{l-1} + b_{ml}^l), \quad (2.18)$$

donde l es la capa para $l = 1, \dots, L$, m_l es el nodo y $\boldsymbol{\theta}_{ml}^l \equiv \{\mathbf{W}_{ml}^l, b_{ml}^l\}$ son

¹Lo que es equivalente a aprender una representación.

²También llamadas nodos.

³En inglés es link function.

los parámetros de la función de activación a determinar bajo la forma de un conjunto de pesos y una constante (o sesgo).

Se define $\mathbf{g}_1(\cdot)$ como el vector que contiene a todas las funciones de activación en una capa $\{g_1^l(\cdot) \dots g_M^l(\cdot)\}'$ en todos los nodos $1, \dots, M$. Por lo tanto, el primer MLP estará dado por la composición de las funciones de activación de cada nodo, en cada capa de la red de *encoding feedforward*

$$\mathbf{f}_t = G(\mathbf{y}_t) = \mathbf{g}_L(\mathbf{g}_{L-1}(\dots(\mathbf{g}_1(\mathbf{y}_t))))). \quad (2.19)$$

Por otro lado, también se define al MLP que funciona como un decodificador de la red. Es decir, una secuencia de capas donde cada una contiene neuronas que operan como funciones de activación sobre la suma de pesos de las entradas, más un sesgo

$$\tilde{\mathbf{y}}_t = F(\mathbf{y}_t) = \tilde{\mathbf{g}}_{L'}(\tilde{\mathbf{g}}_{L'-1}(\dots(\tilde{\mathbf{g}}_1(\mathbf{y}_t)))) \quad (2.20)$$

donde $\tilde{\mathbf{g}}_{L'}$ es el vector de funciones de activación y L' es la cantidad de capas ocultas en la red de *deconding*. Cuando la cantidad de capas ocultas en el encoding es igual a la cantidad de capas ocultas en el decoding $L = L'$ se dice que el AE es simétrico, de lo contrario es asimétrico. Los AE asimétricos, por lo general, presentan varias capas en el *encoding* pero una sola al decodificar, o sea, $L' = 1$. Esto implica que la red de *deconding* es un Perceptrón De Una Capa (SLP).

En suma, el mapeo estático de los factores se puede resumir con los siguientes supuestos del modelo:

- Sup 1) se tiene una función de *encoding* $G_{\theta_G}(\cdot)$
- Sup 2) se tiene función de *deconding* $F_{\theta_F}(\cdot)$.

Por su parte, la dinámica del modelo se puede establecer con los siguientes supuestos:

- Sup 3) \mathbf{f} son vectores lineales estocásticos de ecuaciones en diferencias.
- Sup 4) ε_t son vectores lineales estocásticos de ecuaciones en diferencias con matrices diagonales en los coeficientes autorregresivos.
- Sup 5) las distribuciones de los terminos de error de la ecuación de transición son gaussianas *iid*.

De forma general, el D^2FM se puede expresar como

$$\mathbf{f}_t = G(\mathbf{y}_t) \quad (2.21)$$

$$\mathbf{y}_t = F(\mathbf{f}_t) \quad (2.22)$$

$$\mathbf{f}_t = \mathbf{B}_1 \mathbf{f}_{t-1} + \dots + \mathbf{B}_p \mathbf{f}_{t-p} + \mathbf{u}_t, \quad \mathbf{u}_t \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \mathbf{U}) \quad (2.23)$$

$$\boldsymbol{\varepsilon}_t = \boldsymbol{\Phi}_1 \boldsymbol{\varepsilon}_{t-1} + \dots + \boldsymbol{\Phi}_p \boldsymbol{\varepsilon}_{t-p} + \boldsymbol{\epsilon}_t, \quad \boldsymbol{\epsilon}_t \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \mathbf{Q}) \quad (2.24)$$

con respecto al modelo empleado en Banbura y Modugno (2014), se mantienen los supuestos de linealidad en la parte dinámica de las 2 últimas ecuaciones mientras que se permite un mapeo no lineal entre las variables y los factores. Bajo este esquema, los parámetros del modelo se pueden estimar con el Método de gradiente Monte Carlo.

Con respecto al diseño de la red, el modelo se basa en un AE con una estructura asimétrica, como se aprecia en la figura 2.1.

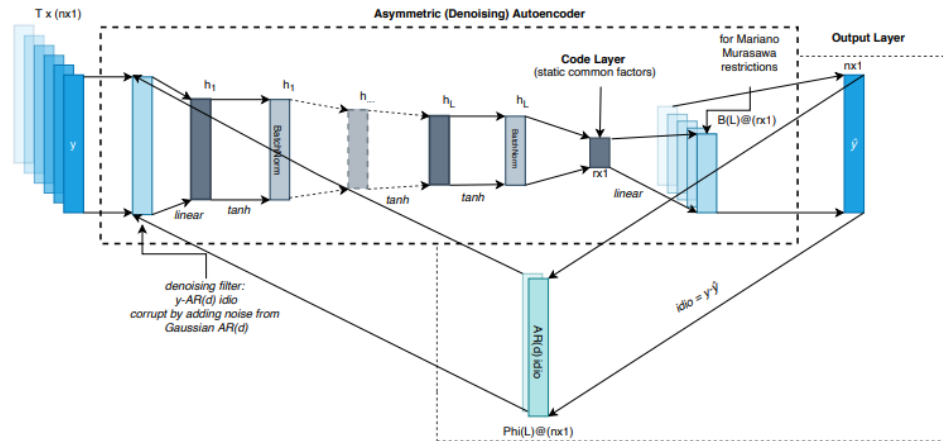


Figura 2.1: Representación del proceso de entrenamiento del modelo D^2FM

La cantidad de capas ocultas y neuronas no está predefinida y se pueden seleccionar con validación cruzada. Las funciones de activación empleadas son *tahn*. Además, en la parte de *encoding* se incluyen dos capas de normalización por lotes para que haya cierta regularización y control sobre potenciales desplazamientos de covariables¹.

¹En inglés: covariate shift

Los autores proponen un procedimiento en dos pasos para diferenciar el aprendizaje en línea² y fuera de línea³:

- Paso 1: se estiman de manera *off-line* todos los parámetros del modelo;
- Paso 2: se representa la parte de *decoding* a un marco de espacios de estados para hacer actualizaciones en línea de los estados latentes dados los observables.

En el paso 1, el siguiente algoritmo 2 es una Cadena de Markov Monte Carlo (MCMC)¹ que implementa un estimación fuera de línea, asumiendo $AR(d)$ para $p_{idio}(\cdot)$, es decir, los componentes idiosincráticos. Precisa un conjunto de entrenamiento, una estructura de *encoding* $G_{\theta_G}(\cdot)$ y una estructura de *decoding* $F_{\theta_F}(\cdot)$.

Algorithm 2 MCMC para D^2FM con componentes idiosincráticos estacionarios $AR(d)$

Init: $\theta_G, \theta_F, \Phi, \Sigma_\varepsilon, \varepsilon_t$

repeat

1: $\tilde{\mathbf{y}}_t | (\mathbf{y}_t, \hat{\varepsilon}_t) = \mathbf{y}_t - \Phi(L)\varepsilon_t$

2: **Loop** epochs, batches **Do**

3: draw $\varepsilon_t^{(mc)} \stackrel{iid}{\sim} \mathcal{N}(0, \Sigma_\varepsilon)$

4: $\mathbf{y}_t^{(mc)} = \tilde{\mathbf{y}}_t | (\mathbf{y}_t, \hat{\varepsilon}_t) + \varepsilon_t^{(mc)}$

5: θ_G, θ_F update by gradient based step on $\hat{\mathcal{L}}(\mathbf{y}_t, F_{\theta_F}(G_{\theta_G}(\mathbf{y}_t^{(mc)})))$

6: **End Loop**

7: $\mathbf{f}_t | \mathbf{y}_t^{(mc)} = \mathbb{E}_{\mathbf{y}_t^{(mc)} \sim \mathbf{y}_t, \hat{\varepsilon}_t} G_{\theta_G}(\mathbf{y}_t^{(mc)})$

8: $\varepsilon_t | \mathbf{y}_t, \mathbf{f}_t = \mathbf{y}_t - F_{\theta_F}(\mathbf{f}_t | \mathbf{y}_t^{(mc)})$

9: $\Phi \leftarrow$ stationary $AR(d)$ on ε_t

10: $\Sigma_\varepsilon \leftarrow$ from ε_t

until convergence on $\hat{\mathcal{L}}(\mathbf{y}_t, F_{\theta_F}(\mathbf{f}_t | \mathbf{y}_t^{(mc)}))$ is less than the predefined tolerance in L_1 norm, or the maximum number of iterations is reached.

return $\Sigma_\varepsilon, \Phi, \mathbf{f}_t, F_{\theta_F}$

En el paso 2, se lleva el resultado del algoritmo a las ecuaciones de espacio de estados (2.23)-(2.24). La dinámica de los factores comunes se estima con mínimo cuadrados ordinarios o máxima verosimilitud. Las actualizaciones de los estados se pueden realizar de varias maneras, los autores sugieren emplear el filtro de kalman.

²En inglés: out-of-sample

³En inglés: in-sample

¹Por sus siglas en inglés relativas a Markov Chain Monte Carlo

Para establecer los hiperparámetros del modelo se realiza una búsqueda por grilla. En general se estiman en base una grilla respecto a alguna función de pérdida y se emplea un método de validación cruzada. Se dividen a los hiperparámetros en dos categorías: una ocupa a la estructura de la red neuronal; la otra se relaciona con el algoritmo de optimización.

Los detalles de la implementación del modelo se detallan en el próximo capítulo [3](#).

Capítulo 3

Estrategia empírica

3.1. Esquema de implementación

En la figura 1.1 se detallan los pasos seguidos para la implementación del preprocesamiento de la series de datos y los modelos empleados en el estudio. Se usaron como lenguajes de programación tanto R¹ como Python² de acuerdo a la disponibilidad de paquetes y funciones. A grandes rasgos el preprocesamiento es el siguiente: primero, se descargan los datos de una url y se procesan para eliminar datos faltantes; segundo, se realizan las Pruebas Dicky-Fuller Aumentado (ADF) y Pruebas de Kwiatkowski, Phillips, Schmidt y Shin (KPSS) para determinar la presencia de raíces unitarias y estacionariedad de las series; tercero, se ordenan las columnas según el esquema resursivo planteado en 3.2; cuarto, se divide a la muestra en entrenamiento y prueba; quinto, se crean los datos de entrada para los modelos lineales. En la etapa de modelado, los procesos podrían correrse en paralelo. En términos generales, habiendo determinado la cantidad óptima de factores, se pasa a determinar el desempeño predictivo para distintas cantidades de los factores en el modelo FAVAR, DFM estimado por EM en R. En python, se implmenta el modelo D^2FM para 6 y 7 factores, para luego evaluar el desempeño predictivo en cada caso. Por último, con los resultados de la estimación de los factores en el caso de 6 factores, para todos los modelos se calculan las funciones de de respuesta al impulso y descomposición de la varianza del error de predicción frente a un aumento de la Tasa de Fondos Federales (FFR) sobre un conjunto de variables de interés.

¹R Core Team (2023)

²Python Software Foundation (2023)

3.2. Datos del estudio

3.2.1. Fuente del conjunto de datos a emplear

El conjunto de datos empleado en el presente estudio es el propuesto por McCracken y Ng (2016). Los datos surgen de un trabajo colaborativo con la Reserva Federal de St. Louis y se emplean Datos Económicos de la Reserva Federal (FRED)¹ para la economía de Estados Unidos. Como consecuencia, la *FRED-MD*² es una amplia base de datos macroeconómica con frecuencia mensual que tiene como objetivo establecer un punto de partida común para el análisis empírico en el marco de lo que se denomina *Big Data*.

La base de datos se asemeja a lo que se conoce en la literatura como el conjunto de *datos de Stock y Watson* y su recolección está guiada por cuatro recomendaciones: primero, la muestra debería incorporar los principales agregados mensuales y sus indicadores relacionados; segundo, debería incluir como consecuencia los principales indicadores económicos; tercero, los datos deberían representar un amplio conjunto de variables con distintas propiedades de series de tiempo; cuarto, los datos deberían tener definiciones históricas consistentes y, en caso contrario, que sean sujetas a revisiones y actualizaciones. En este sentido, a través de la *FRED-MD* se busca brindar una base de datos accesible, actualizada y común para la comunidad científica.

¹Por sus siglas en inglés relativas a Federal Reserve Economic Data.

²Base de datos mensual para la investigación macroeconómica.

3.2.2. Preprocesamiento de las series de tiempo

3.2.2.1. Carga y transformación de las series temporales

Los datos se cargan y preprocesan usando distintos paquetes de R¹. En este sentido, el paquete `fbi`², propuesto por Chen et al. (2023), contiene funciones para estimar modelos de factores, para imputar datos faltantes y para cargar y preparar al conjunto de datos *FRED-MD*. Con la función `fredmd` se cargan los mismos y se manipulan realizando las transformaciones sugeridas con el objetivo de que las series temporales sean estacionarias. Cada serie temporal se asocia a un código de transformación denominado `tcode`. La descripción de cada columna de datos y sus transformaciones se pueden hallar en el Apéndice 1, secciones 1.1 y 1.2, respectivamente.

En total se cuenta con 128 columnas relativas a 127 variables macroeconómicas y la columna temporal mensual. Las variables se clasifican en 8 categorías: Consumo, órdenes e inventarios; Vivienda; Intereses y tipos de cambio; Mercado de trabajo; Dinero y crédito; Producto e ingreso; Precios; Mercado de activos. Su clasificación también tiene como antecedente estudios de Stock y Watson.

Una vez que se obtienen los datos transformados, se pasa a remover los datos atípicos empleando la función `rm_outliers.fredmd`. Luego, se eliminan columnas con 5 % o más datos faltantes (NA). Como consecuencia se pasa a tener una grilla de datos de 751 filas con 123 columnas. Luego de chequea la presencia de NA al inicio y al final de la grilla de datos y se eliminan filas hasta que no halla más NA en los extremos de la misma. Una vez realizado lo anterior, se pasa a imputar los restantes NA empleando la función `na_kalman` del paquete `imputeTS`, propuesto por Moritz y Bartz-Beielstein (2017). Este paquete sirve para imputar datos faltantes en series univariadas. Para este estudio se emplearon los argumentos `model = "StructTS"`, `smooth = TRUE` de la función `na_kalman`, por lo que se ajusta a cada serie un modelo estructural por máxima verosimilitud y se suavizan los datos empleando el filtro de Kalman.

Siguiendo con el preprocesamiento de los datos, se pasa a chequear que la columna de fechas (`date`) sea completa, o sea, considerando la fecha mínima (t_{min}) y máxima (t_{max}) de la muestra, que no haya ninguna fecha intermedia

¹R Core Team (2023)

²Factor-Based Imputation and FRED-MD/QD Data Set

t faltante.

Realizado lo anterior, se obtiene un conjunto de datos con 722 filas y 123 columnas (incluyendo la columna temporal de fecha), por lo que se cuenta con 122 variables económicas en total. La fecha de inicio del estudio es 1960-01-01 y la fecha máxima es 2020-02-01.

3.2.2.2. Análisis de raíces unitarias y estacionalidad

Dado que la política monetaria en Estados Unidos ha cambiado significativamente en los últimos 20 años como resultado de varias crisis económicas y especulativas, y que los datos de este estudio abarcan un período de tiempo considerablemente largo, no sería esperable que las series sean estacionarias en todo el período analizado. En estudios posteriores, se podría realizar el análisis para ventanas de tiempo más reducidas asociadas a los distintos momentos históricos de la política monetaria estadounidense.

En la presente subsección se chequea que las series resultantes del preprocesamiento anterior sean estacionarias para todo el período considerado. Para entender el concepto de estacionariedad ver Apéndice 3.1.

En la literatura existen varios métodos para testear la presencia de raíces unitarias en series temporales. Sin embargo, en el presente estudio, en un primer momento, se van a considerar las pruebas ADF¹ para poner a prueba la hipótesis nula de existencia de raíces unitarias en z_t (Apéndice 3.2). Por otra parte, siguiendo a Shin et al. (1992), desde el punto de vista empírico, para series económicas, en general, las pruebas de raíz unitaria fallan en rechazar la hipótesis nula de raíz unitaria cuando en realidad contienen raíces unitarias. Para hacer frente a esta debilidad de las pruebas ADF, se va a emplear una prueba alternativa, denominada KPSS, con hipótesis nula de estacionariedad contra una alternativa de raíz unitaria para cada serie temporal (Apéndice 3.3).

Cuando los resultados de ambos test indican que una serie z_t sería estacionaria con un determinado nivel de confianza, se puede concluir que los resultados son confirmatorios, en caso contrario son robustos.

Para llevar a cabo las mencionadas pruebas, se emplea el módulo `arch` de `python` desarrollado por Sheppard et al. (2023). Se crearon dos clases: `ModelsADF`, para los test ADF con los modelos con constante y con tendencia (`ct`), con constante determinística (`c`) y sin constante ni tendencia (`n`). En cada caso se obtiene la cantidad de series que no presentarían RU (y que si) con un 95 % de confianza y la lista de variables macroeconómicas; `PSSAnalysis`, para las pruebas KPSS con distintas formas de estimar la cantidad de rezagos y para las hipótesis nulas de estacionariedad alrededor de una tendencia (`ct`) y una constante (`ct`). Para esta prueba se obtiene también la cantidad de

¹Por sus siglas en inglés relativas a Augmented Dickey-Fuller.

series no estacionarias, estacionarias y la lista de variables en cada caso, para el mismo nivel de confianza.

Resultados de las pruebas ADF y KPSS: partiendo de un modelo general 3.4 para la prueba ADF, se tiene que un total de 118 series no presentarían raíz unitaria con un 95 % de confianza, por lo que se las puede considerar estacionarias. Sólo cuatro series serían no estacionarias y las mismas son HOUSTNE, HOUSTMW, HOUSTS, PERMITMW. Los resultados se detallan en el Apéndice 3.4.1.

Con respecto a los resultados del test KPSS (ver Apéndice 3.4.2), la prueba se realizó considerando varios esquemas para determinar la cantidad de rezagos (**legacy**, **auto**, **Newey West**, y **Schwert**) para las hipótesis nulas de estacionariedad alrededor de una constante y una tendencia. Dado que se espera que las series sean estacionarias porque se aplicaron las transformaciones sugeridas como se mencionó antes, se elige un resultado del test en base a la mayor cantidad de series que son estacionarias con un 95 % de confianza. Como conclusión de las pruebas realizadas, cuando la cantidad de rezagos se determina en base al criterio **legacy** es decir, cantidad de lags = $12 \times (T/100)^{(1/4)}$, con T siendo la cantidad de períodos, y la hipótesis nula es de serie estacionaria alrededor de una tendencia, se tiene que 105 series son estacionarias y 17 no serían estacionarias. En el siguiente cuadro 3.1 se tiene la cantidad de series estacionarias y no estacionarias para cada una de las pruebas ADF y KPSS bajo las formas antes mencionadas.

Tabla 3.1: Cantidad de series estacionarias y no estacionarias

	Estacionarias	No estacionarias
ADF	118	4
KPSS	105	17

Bajo este resultado, para las 4 series que no son estacionarias según ADF, 3 no son estacionarias según KPSS por lo cual, para 3 de 4 series los resultados confirman que no son estacionarias. En total 15 series presentan resultados contradictorios según los resultados de las pruebas. Dado que se siguieron las recomendaciones de transformación de las series de McCracken y Ng (2016) para transformarlas en estacionarias, se opta por descartar del estudio únicamente a las 3 series de datos para las cuales los resultados de no estaciona-

riedad son confirmatorios con ambos tests, esto es HOUSTMW, HOUSTS y PERMITMW. Los resultados de los modelos menos generales coinciden para un nivel de confianza del 95 % en que para éstas series habría evidencia de presencia de RU. Se podría profundizar en el análisis con los estadísticos F asociados a cada modelo pero al no ser el centro de este estudio y porque se parte de la idea de que las series deberían ser estacionarias, se trunca el análisis de las pruebas ADF en esta etapa.

3.2.2.3. Conjunto de datos de entrenamiento y prueba

Trás eliminar las series temporales no estacionarias se procede a ordenar los datos en variables lentas, rápidas y tasa de interés de referencia (ver Apéndice 5.1) de cara a la identificación del modelo FAVAR de la próxima sección, para luego dividir a la muestra en conjuntos de entrenamiento y prueba.

Las variables se clasifican en lentas o rápidas de acuerdo a los criterios de Bernanke et al. (2005). Como resultado, se agrupa a las series macroeconómicas en lentas primero, después rápidas y se coloca a la serie relativa a la tasa de interés de referencia como última columna del conjunto de datos.

En una etapa posterior se divide a la muestra en datos de entrenamiento y prueba. De esta forma, los datos de entrenamiento, considerando al índice temporal ordenado de manera ascendente, abarcan el 80 % de la muestra y el restante 20 % de los datos son el conjunto de prueba. Como se está en un contexto de series temporales, el conjunto de entrenamiento constituye los datos más antiguos mientras que el conjunto de datos de entrenamiento está compuesto por datos más recientes. De esta manera, el conjunto de entrenamiento está compuesto por 577 filas y su rango de fechas es de 1960-01-01 al 2008-01-01. Mientras que el conjunto de prueba es de 145 filas empezando el 2008-02-01 hasta 2020-02-01.


3.3. Implementación de los DFM lineales

3.3.1. Determinación de la cantidad óptima de factores

Siguiendo a Stock y Watson (2016), para estimar la cantidad de factores estáticos r se puede emplear una combinación de herramientas: conocimiento a priori, gráficos como el *scree plot* y criterios de información, entre otros.

El *scree plot* muestra la contribución marginal del k -ésimo componente principal al promedio de R^2 de los N regresores de X_t contra los primeros k componentes principales. Para este estudio, los regresores X_t se corresponden con la muestra de entrenamiento. Como no hay datos faltantes, el *scree plot* grafica los valores propios ordenados de $\hat{\Sigma}_X$ normalizados por la suma de los valores propios, como se observa en la siguiente figura 3.1.

Figura 3.1: Scree plot de los valores propios ordenados



Con respecto a los criterios de información, Bai y Ng (2002) extienden el de *Akaike* que penaliza una función objetivo compensando el beneficio de incluir parámetros adicionales contra el costo de incrementar la variabilidad de la muestra, al incluir un factor adicional tal que


$$IC(r) = \ln V_r(\hat{\Lambda}, \hat{F}) + r \times g(N, T) \quad (3.1)$$

donde $V_r(\hat{\Lambda}, \hat{F})$ es la función objetivo de mínimo cuadrados en 2.5 evaluada en $(\hat{\Lambda}, \hat{F})$ y $g(N, T)$ es el factor de penalización que tiende a cero a medida que

N y T tienden a infinito.

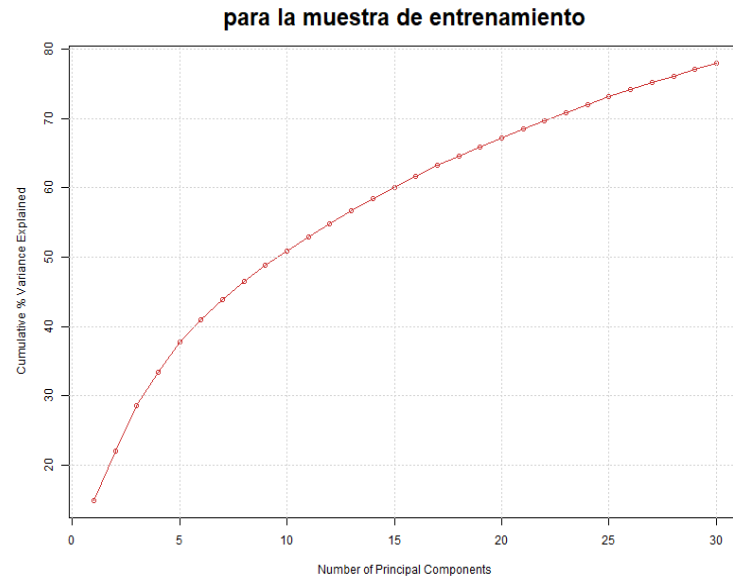
Una función de penalización típica es la IC_{p2} para la cual $g(N, T) = [(N + T) / (NT)] \ln(\min(N, T))$. Para este estudio, $IC_{p2} = 7$ como se aprecia en la figura 3.2, lo que indicaría que la cantidad óptima de factores es igual a ese número.

Figura 3.2: Criterios de informacion



Dado que para 5 factores se acumula casi el 40 % de la varianza explicada (figura 3.3), se va a comparar el desempeño predictivo de los modelos DFM lineales para 3, 4, 5, 6 y 7 factores.

Figura 3.3: Scree plot de la varianza explicada acumulada



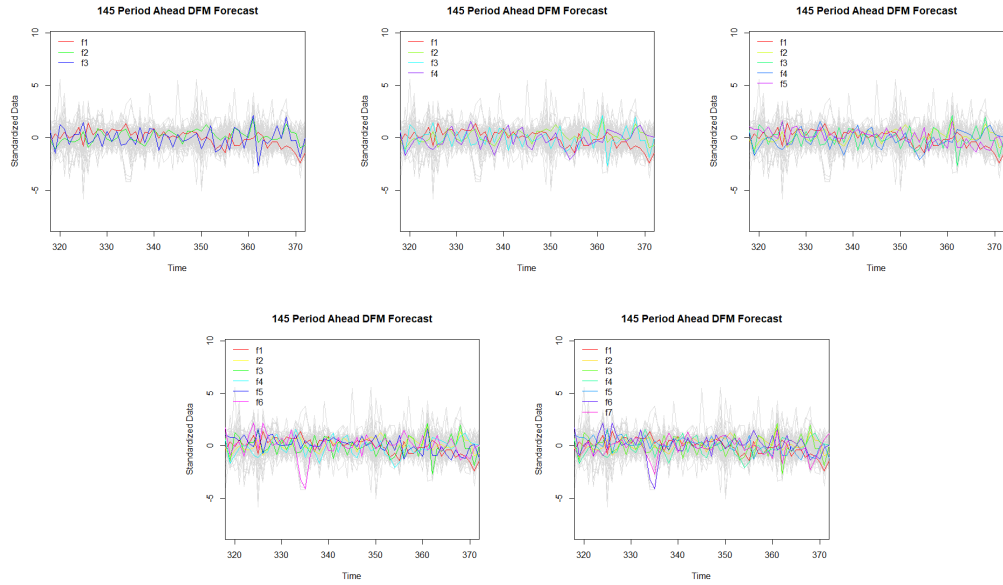
Para obtener los scree plots y la cantidad óptima de factores con IC_{p2} se empleó el paquete `dfms` en R propuesto por Krantz y Bagdziunas (2023).

3.3.2. Implementación del DFM con Algoritmo EM

Para estimar un modelo DFM en su forma estática sin considerar factores observables, se emplea el algoritmo EM empleado en Banbura y Modugno (2014) con el paquete `dfms` en R desarrollado por Krantz y Bagdziunas (2023). Para esto se emplea la función `DFM` sobre los datos de entrenamiento ya escalados para la secuencia de 3 a 7 factores, asumiendo un $VAR(1)$ en la parte autorregresiva, matriz de covarianzas Q identidad de la ecuación de transición, matriz de covarianzas R en la ecuación de medida diagonal, y como método de estimación el algoritmo *EM*.

Un vez estimado el modelo, con la función `predict` se calculan las predicciones, considerando el largo del conjunto de datos de prueba, esto es, 145 pasos hacia adelante para los factores y para los datos X_{t+s} con s representando los pasos hacia adelante. Como se observa en los subgráficos de la figura 3.4, las predicciones de los factores mejoran a medida que los factores se acercan al óptimo de 7 determinado por el IC_{p2} .

Figura 3.4: Predicciones 145 pasos hacia adelante para distinta cantidad de factores



Una vez halladas las predicciones para X_{t+s} , se pasa a calcular el error de predicción promedio, como se detalla en la próxima sección 4.

3.3.3. Implementación del modelo FAVAR

Siguiendo a Bernanke et al. (2005), para implementar el modelo FAVAR, se parte de su identificación, esto es, se establece un ordenamiento de las variables en el sistema. Se ubica a la FFR última y sus innovaciones se interpretan como *shocks* de política monetaria. Este ordenamiento impone el siguiente supuesto de identificación: los factores latentes no responden a las perturbaciones de política monetaria en el período. A su vez, se agrupan a las variables en dos categorías: de movimiento lento y rápido. Las variables de movimiento lento, están en gran medida predeterminadas en el período actual. Lo anterior implica que esa categoría de variables, como puede ser el empleo, el producto y los precios, no se ven afectados por perturbaciones de política monetaria en el período. Por su parte, las de movimiento rápido son altamente sensibles a cambios contemporáneos relativos a perturbaciones o novedades en la economía. Considerando la categorización de variables, se va a establecer el siguiente ordenamiento en el modelo bajo un esquema recursivo tal que

$$\begin{pmatrix} X_t^s \\ X_t^f \\ r_t \end{pmatrix} = \begin{pmatrix} \Lambda_{ss} & 0 & 0 \\ \Lambda_{fs} & \Lambda_{ff} & \Lambda_{fr} \end{pmatrix} \begin{pmatrix} F_t^s \\ F_t^f \\ r_t \end{pmatrix} + e_t, \quad (3.2)$$

$$\phi(L) \begin{pmatrix} F_t^s \\ F_t^f \\ r_t \end{pmatrix} = \begin{pmatrix} \eta_t^s \\ \eta_t^f \\ \eta_t^r \end{pmatrix}, \quad (3.3)$$

$$\begin{pmatrix} \eta_t^s \\ \eta_t^f \\ \eta_t^r \end{pmatrix} = \begin{pmatrix} H_{ss} & 0 & 0 \\ H_{fs} & 1 & 0 \\ H_{rs} & H_{rf} & H_{rr} \end{pmatrix} \begin{pmatrix} \varepsilon_t^s \\ \varepsilon_t^f \\ \varepsilon_t^r \end{pmatrix} \quad (3.4)$$

A su vez, se restringe al modelo en sus factores tal que $F^T F = I$ por lo que $\hat{F} = \sqrt{T} \hat{Z}$ donde \hat{Z} son los vectores propios de los k mayores valores propios de XX^T ordenados de manera descendiente.

Para la estimación en dos etapas por CP se sigue el código en R de Duarte (2020). La identificación del modelo requiere que primero se controle la parte de \hat{C}_t que se corresponde con la FFR. Entonces, primero se estiman los factores de movimiento lento F_t^s por CP para las variables de movimiento lento. Luego, se estima la siguiente regresión

$$\hat{C}_t = b_{F^s} \hat{F}_t^s + b_Y Y_t + e_t, \quad (3.5)$$

donde $\hat{F}_t = \hat{C}_t - \hat{b}_Y Y_t$.

Por último, se estima el VAR en \hat{F}_t y Y_t con el paquete `vars` en R propuesto por Pfaff (2008), considerando un bucle con los distintos valores de los factores inobservables de 3 a 6¹. Para cada valor de los factores inobservables, se emplea la función `var.select` que permite encontrar la cantidad óptima de rezagos del VAR de acuerdo a varios criterios de selección, para este estudio se toma el criterio *AIC*. Luego, se estima el VAR con la función `var` y se hallan las predicciones con 145 pasos hacia adelante con la función `predict`. Por último, se emplean las matrices de pesos estimadas $\hat{\Lambda}^f$ y $\hat{\Lambda}^y$ para hacer las predicciones de X_{t+s} con s representando los pasos hacia adelante.

Una vez halladas las predicciones para X_{t+s} , se calculan las métricas de desempeño promedio del modelo como se detalla en la próxima sección 4.

¹Considerando que se agrega el factor observable FFR.

3.4. Implementación del modelo no lineal

3.4.1. Implementación del modelo D^2FM

Andreini et al. (2023b) emplean distintos esquemas del D^2FM para realizar simulaciones e investigación empírica¹. Para el caso empírico, que es el de este estudio, especifican un mapeo lineal entre los factores y las variables de la forma $\mathbf{y}_t = \mathbf{A}\mathbf{f}_t\boldsymbol{\varepsilon}_t$. Como consecuencia plantean un modelo D^2FM *más sencillo* que el detallado en la sección previa 2.2. El mismo sería una generalización del enfoque de Bai y Ng (2008) en el cual se aplican CP para predictores objetivo (*targeted predictors*) permitiendo no linealidades entre los predictores y los factores. Esta forma de plantear el modelo tiene una serie de ventajas según los autores. Una, mantendría los mismos niveles de interpretabilidad que un DFM lineal. Otra, al estar en un esquema de aprendizaje profundo, permite ir en la dirección de la construcción de modelos más complejos.

El modelo se implementa en `python` siguiendo y ampliando el código de Andreini et al. (2023a). En la siguiente figura 3.5 se detallan las sugerencias de las elecciones de los hiperparámetros del mismo.

Figura 3.5: Características y elecciones en el modelo

Model Components		Hyperparameter	Choice taken
Autoencoder	Model Structure	number of hidden layers	3
		number of neurons for each layer	selected via cross-validation
		penalisation	none
		dropout layers and rates	none
	Optimization	batch norm layers	2 included in the encoding network
		link function	used tanh
		size of mini batches	100 monthly observations
		number of epochs	100 for each MC iteration
Dynamic Equations	Model Structure	optimisation algorithm	ADAM with default parameters
		number of latent states	selected via cross-validation
		number of lags input variables	selected via cross-validation
		number of lags for latent common states	2 as in Banbura and Modugno (2014)
		number of lags for idiosyncratic states	1 as in Banbura and Modugno (2014)

Primero, como en la sección anterior se determinó que la cantidad óptima de factores es 7, se asume que esa es la verdadera cantidad de factores. Dado que luego, se va a realizar un análisis de impacto de política monetaria con

¹Además de que emplearon un conjunto de datos con frecuencias mixtas y datos faltantes para el caso empírico.

el supuesto de que un factor es observable, se comparan resultados cuando se tienen 7 y 6 factores.

Segundo, como no hay antecedentes para determinar la cantidad de nodos en cada capa oculta se parte considerando la cantidad de nodos que los autores emplearon para el caso de las simulaciones de polinomios de segundo grado y se prueba con otro escenario que lleva al doble la cantidad de neuronas por capa oculta.

Tercero, se asumió que la cantidad de estados latentes es igual a 1 y se prueba con los valores 0 y 1 para la cantidad de rezagos de las variables de entrada para tener un punto de partida analítico y simplificar los resultados.

Tanto en la fase de preentrenamiento como de entrenamiento de optimiza con empleando *ADAM* para 100 épocas. Antes del entrenamiento se reinicia *ADAM* y luego se corre por batches de tamaño 100 observaciones mensuales. En la parte del entrenamiento de vuelven a fijar 100 épocas para cada iteración del MCMC, que permiten actualizar la distribución idiosincrática. Los parámetros se inician en dos etapas: primero con una inicialización de Xavier, los pesos en las funciones de enlace se muestrean a partir de una gaussiana con media cero y varianza $2/(n_{in} + n_{out})$ donde n_{in} es la cantidad de unidades de entrada y n_{out} es la cantidad de unidades de salida. Se preentrena al modelo para ejercitar a la cadena.

Se ajusta el modelo considerando las distintas estructuras mencionadas y se elige aquel con menor valor final para la función de pérdida.

Listing 3.1: Determinación la estructura del modelo

```
-----  
r # cantidad de factores  
structure_encoders = [(r * 6, r * 4, r * 2, r),  
(r * 12, r * 6, r * 4, r)]  
lags_inputs = list(range(2))  
model_info = []  
for use_bias_setting in [True, False]:  
    for structure_encoder in structure_encoders:  
        for lags_input in lags_inputs:  
            ddfm = DDFM(df_train_idx,  
  
                        lags_input=lags_input,  
                        structure_encoder=structure_encoder,  
                        optimizer='Adam', factor_order=1,  
                        use_bias=use_bias_setting,  
                        link='tanh',  
                        epochs=100, max_iter=1000)  
            # Fit the model  
            ddfm.fit()  
-----
```

Para el caso de 6 factores llega a que, tras convergencia, la función de pérdida final mínima se da para un modelo con cantidad de nodos en cada capa del encoder igual a 72, 36, 24, 6 nodos por capa y rezagos en las variable de entrada igual a 1. Los resultados también indican que la función de pérdida es menor cuando no se considera sesgo en el decoder.

Para 7 factores, la función de pérdida mínima se da con una estructura de encoder igual a 84, 42, 28, 7 nodos por capa y la cantidad de rezagos de entrada igual a 1 pero con sesgo en el decoder.

Trás ajustar los modelos antes mencionados, se pasa a realizar las predicciones con 145 pasos hacia adelante para luego calcular el error de predicción, que se detalla en la próxima sección [4](#).

Capítulo 4

Evaluación de los modelos

4.1. Métricas de desempeño predictivo

Para los tres modelos considerados se emplean tres métricas de desempeño predictivo. Se comparan las predicciones en cada caso en relación a los datos de prueba escalados. Dado que el tamaño de la muestra de este conjunto de prueba es igual a 145, se tiene la misma cantidad de pasos para adelante para las predicciones cada variable i con $i = 1, \dots, N$.

- Mean Absolute Error¹: $MAE_i = \frac{1}{T} \sum_{t=1}^T |y_{i,t} - \hat{y}_{i,t}|$
- Mean Squared Error²: $MSE_i = \frac{1}{T} \sum_{t=1}^T (y_{i,t} - \hat{y}_{i,t})^2$
- Root Mean Squared Forecast Error³: $RMSFE_i = \sqrt{\frac{1}{T} \sum_{t=1}^T (y_{i,t} - \hat{y}_{i,t})^2}$

La evaluación de los modelos se realiza tomando los promedios de cada métrica

$$\text{Métrica promedio} = \frac{1}{n} \sum_{i=1}^n \text{metrica}_i \quad (4.1)$$

¹Error Medio Absoluto

²Error Cuadrado Medio

³Raíz del Error Cuadrático Medio pronosticado

4.2. Resultados para el DFM estimado con algoritmo EM

Tabla 4.1: Métricas promedio de desempeño para cada modelo con DFM

Cantidad de factores	MAE	MSE	$RMSFE$
3	0.6929408	0.9890798	0.9945133
4	0.6927371	0.9870652	0.9934740
5	0.6839955	0.9580894	0.9785842
6	0.6825018	0.9537755	0.9761837
7	0.6840496	0.9574410	0.9774100

Si bien los resultados de las métricas promedio son bastante cercanos para el caso de un modelo con 6 y 7 factores, se tiene que para el modelo con 6 las medidas son mínimas.

4.3. Resultados para el modelo FAVAR

Tabla 4.2: Métricas promedio de desempeño para cada modelo con FAVAR

Cantidad de factores	MAE	MSE	$RMSFE$
3	0.6872627	0.9703477	0.9848100
4	0.6840958	0.9609026	0.9797724
5	0.6845768	0.9599503	0.9788059
6	0.6882497	0.9672635	0.9824071
7	0.6840139	0.9555390	0.9766843

Para el modelo FAVAR también se tiene que los resultados de las métricas no son muy distintos para los distintos factores, sin embargo en este caso los menores resultados se dan para 7 factores.

4.4. Resultados para el modelo D^2FM

En el caso del modelo de aprendizaje profundo, se realizó el análisis de desempeño predictivo para 6 y 7 factores unicamente. El motivo se basa en que para los modelos de referencia, con 6 y 7 factores, se obtienen las mejores predicciones.

Tabla 4.3: Métricas promedio de desempeño para cada modelo con D^2FM

Cantidad de factores	\overline{MAE}	\overline{MSE}	\overline{RMSFE}
6	0.6897566	0.9770122	0.9884393
7	0.6889207	0.9742072	0.98701933

Para este modelo, se tiene que las métricas promedio son menores para el caso de 7 factores.

Capítulo 5

Análisis de impacto de política monetaria

5.1. Definición de la política monetaria

En la presente sección se analizan los efectos de una política monetaria contractiva sobre lo que se considera *el resto de la economía*. La FED, 2018 a través de la política monetaria tiene como objetivo promover de manera efectiva un máximo nivel de empleo, estabilidad de precios, así como también moderar las tasas de interés de largo plazo. En este sentido, se dice que la FED tiene un mandato dual: en la medida que los individuos se encuentren trabajando¹ y que el nivel de precios se mantenga estable y en niveles bajos, van a estar dadas las condiciones para fijar tasas de interés en niveles moderados. Las decisiones de política monetaria se llevan a cabo anualmente, considerando los mencionados dos objetivos, teniendo como instrumento las metas para la FFR. Los canales de transmisión de la política monetaria se dan a través de las condiciones crediticias generales de la economía, esto es, tasas de interés, precios de los activos, tipos de cambio y expectativas de los agentes. Y se espera que los resultados de la mencionada política económica se den sobre la demanda general de bienes y servicios.

Tres principios guían la PM de Reserva Federal (FED). Primero, la PM tiene que ser comunicada y sistemática. Segundo, el Banco Central debe proporcionar estímulo a la política monetaria cuando la actividad económica esté por debajo del nivel asociado con la utilización plena de recursos y la inflación esté por debajo de su meta. Por el contrario, se debe implementar una política monetaria contractiva cuando la economía esté sobrecalentada y la inflación esté por encima de su objetivo declarado. Un tercer principio es que el Banco Central debe aumentar la tasa de interés de política monetaria, con el tiempo, en más de uno por uno en respuesta a un aumento persistente en la inflación y disminuir la tasa de política más de uno por uno en respuesta a una disminución persistente en la inflación.

¹O puedo encontrar trabajo de manera rápida.

5.2. Funciones de respuesta al impulso y descomposición de la varianza

Para analizar los efectos de una PM contractiva, se considera subconjunto de variables que se detalla en el Apéndice 6. Las variables macroeconómicas de interés fueron seleccionadas siguiendo el estudio de Bernanke et al. (2005). Como resultado, se eligieron variables similares siempre y cuando estuvieran disponibles. En este marco, se aplica una política monetaria contractiva, aumentando la FFR. Entonces, se analizan los efectos sobre las 19 variables macroeconómicas de interés dada una innovación de 25 puntos básicos en la FFR. Para ésto se siguen los cálculos de la Funciones de respuesta al impulso (FIR) y Descomposición de la varianza (DV) en Duarte (2020) para cada modelo tomando 7 factores en total: 6 factores inobservables estimados y la FFR observable.

En Christiano et al. (1999) se analiza los efectos de un choque exógeno de política monetaria sobre la economía. Plantean que la literatura no ha llegado a definir, de manera consensuada, un conjunto particular de supuestos para identificar los efectos de una perturbación exógena de PM. Frente a la pregunta de qué modelo emplear para conducir experimentos de política, plantean que distintos modelos responden de manera distinta a perturbaciones de PM. Se basan en el programa de Lucas, siguiendo tres pasos: uno, se aíslan los choques de PM para las economías reales y se caracteriza la naturaleza de los experimentos monetarios; dos, se caracteriza la respuesta de la economía frente a los experimentos de PM; tercero, se realizan los mismos experimentos para los modelos a evaluar y se comparan los resultados con los verdaderos de la economía. Estos pasos fueron diseñados de cara a la selección de un modelo que responda a la interrogante de cómo responde la economía frente a un shock de PM.

Es necesario saber lo que efectivamente ocurre en la economía tras un shock de PM. Para aislar los choques de PM se realizan supuestos de identificación para estimar los parámetros de la regla de retroalimentación de la FED. Es decir, la regla que vincula las acciones de política con el estado de la economía. Un supuesto fundamental es el de recursividad, es decir, las variables macroeconómicas son ortogonales a los shocks de política monetaria. Aunque es un supuesto controversial y se han planteado otros esquemas en la literatura, abandonarlo implica también establecer otras identificaciones para las

relaciones económicas. En el debate, como ejemplo, otros autores han planteado que la FED no se fija en el nivel de precios contemporáneo o el nivel de producto para fijar los instrumentos de política y que los movimientos contemporáneos de la tasa de interés no afectan directamente al producto agregado de la economía. Aunque todavía no se haya llegado a un acuerdo en cuanto a los esquemas de identificación de los efectos de PM sobre la economía, hay acuerdo en sus efectos cualitativos. En este sentido, tras una perturbación contractiva de PM, las tasas de interés de corto plazo deberían crecer; el producto agregado, el empleo, los beneficios y los agregados monetarios deberían decrecer; el nivel general de precios debería responder de manera lenta; las medidas de los salarios deberían caer en cantidades modestas. Y los tipos de cambio deberían depreciarse inicialmente. Además, hay acuerdo en que los shocks de PM son responsables sólo de una parte pequeña del porcentaje de volatilidad del producto agregado y de una cantidad incluso menor para los movimientos del nivel de precios generalizado.

5.2.0.1. Funciones de respuesta al impulso

Para el cálculo de las FIR y DV se toman las estimaciones de los factores en cada modelo. Con ésto, se determina un modelo *VAR* y se selecciona la cantidad de rezagos como se hizo anteriormente para el modelo FAVAR. Es decir, se emplea el criterio de *Akaike* para la selección de los rezagos del *VAR*. Luego, se calculan las FIR con la función `irf` del paquete `vars`. Como en Duarte (2020) y en Bernanke et al. (2005), primero se calcula la función de respuesta al impulso frente a una perturbación de 25 puntos porcentuales de la FFR con respecto a si misma `irf` 48 meses hacia adelante. Luego, se halla el impulso estandarizado y la respuesta de la variable en el momento 0. Se procede a realizar 500 simulaciones Bootstrap con remuestreo `boot.scheme = "resample"` para estimar las FIR con modelos *VAR* con constante. Las FIR de cada variables de interés de calcula 48 tiempos hacia adelante. Por último, se obtienen las siguientes figuras 5.1, 5.2 y 5.3.

Trás un aumento de la FFR, se espera que las variables IP index, CPI, Capacity utilization, Real personal consumption, durable good consumption, nondurable goods consumption, Employment, Avg hourly earnings, housing starts, New orders y Dividend Yield caigan. Esto es así porque se espera que las medidas asociadas al producto, ingresos, empleo, inversión residencial, órdenes

e inventarios y beneficios caigan. Además, con algún retraso también se espera que los agregados monetarios M1, M2 también respondan decreciendo. Y se espera que las tasas de interés de corto plazo (3-Month Treasury Bill) aumente aunque para el caso de la tasa de interés de largo plazo no se espera que responda rápidamente. Las variables se agrupan en la siguiente tabla 5.1.

Tabla 5.1: Variables para análisis de impacto de PL

variable	group
Real Consumption	Cons., Orders, and Invent.
New Orders	Cons., Orders, and Invent.
Housing Starts	Housing
Fed Funds Rate	Interest and Exchange Rates
3-Month Treasury Bill	Interest and Exchange Rates
5-Year Treasury Rate	Interest and Exchange Rates
Ex rate: Japan	Interest and Exchange Rates
Civilian Employment	Labor Market
Civilian Unemployment Rate	Labor Market
Avg Hourly Earnings	Labor Market
M1	Money and Credit
M2	Money and Credit
IP Index	Output and Income
Capacity Utilization: Manufacturing	Output and Income
CPI : All Items	Prices
CPI : Commodities	Prices
Personal Cons. Exp: Durable goods	Prices
Personal Cons. Exp: Nondurable goods	Prices
SP div yield	Stock Market

Figura 5.1: Funciones de respuesta al impulso en FAVAR

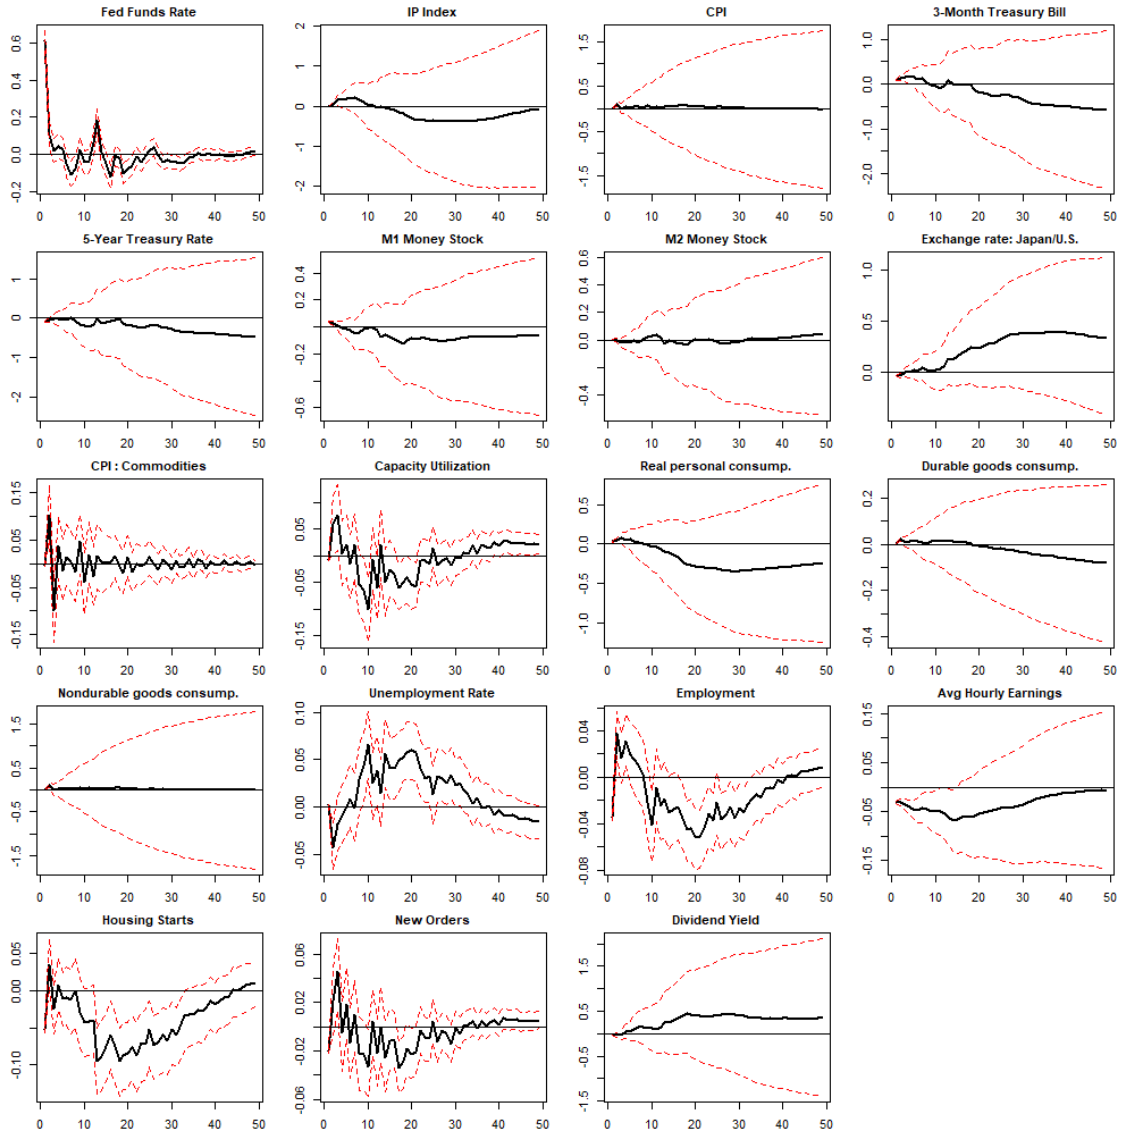


Figura 5.2: Funciones de respuesta al impulso en DFM estimado por algoritmo EM

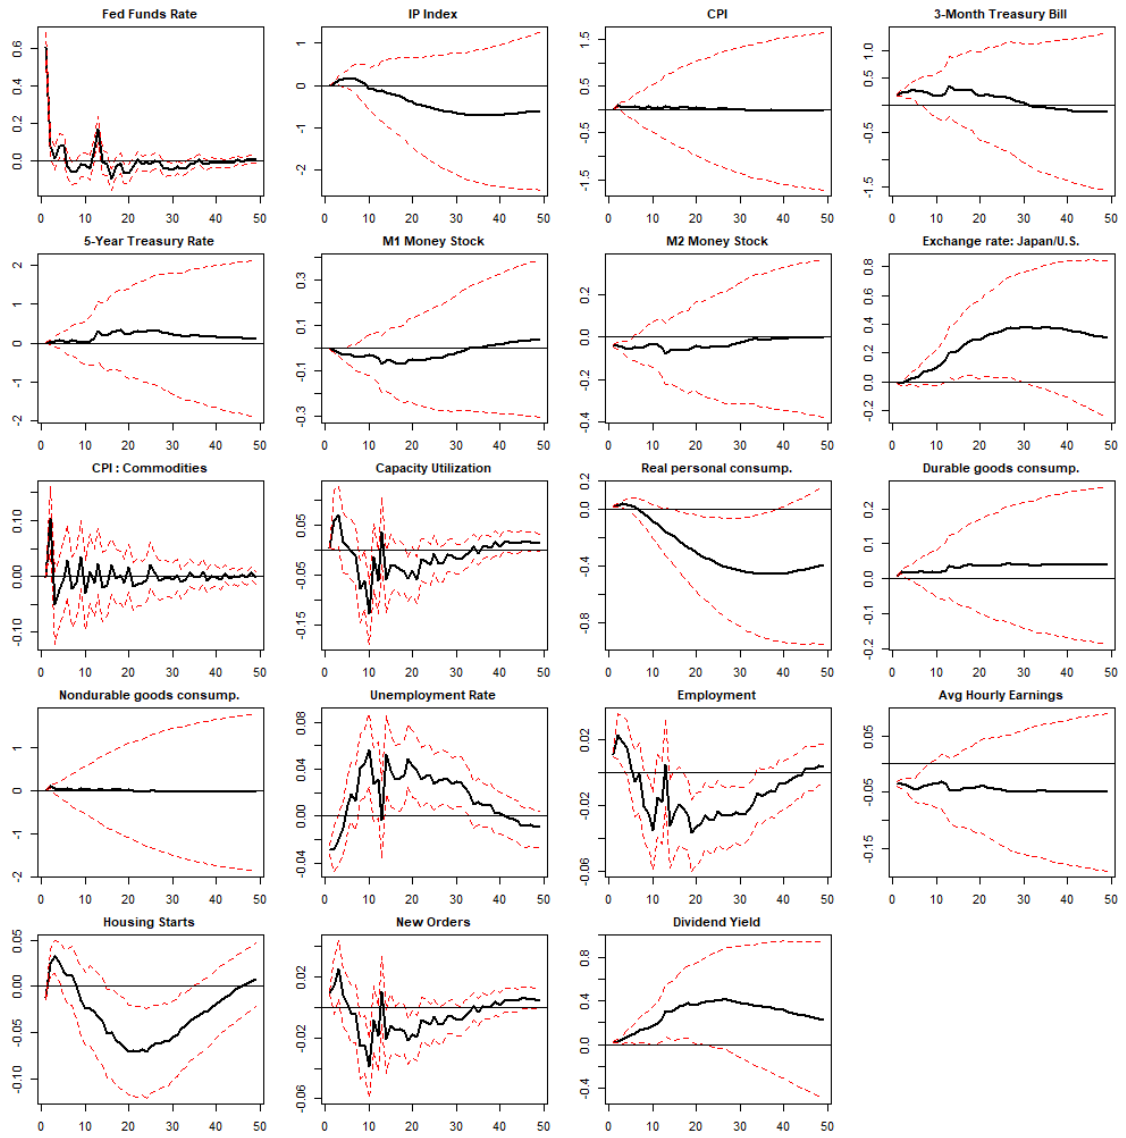
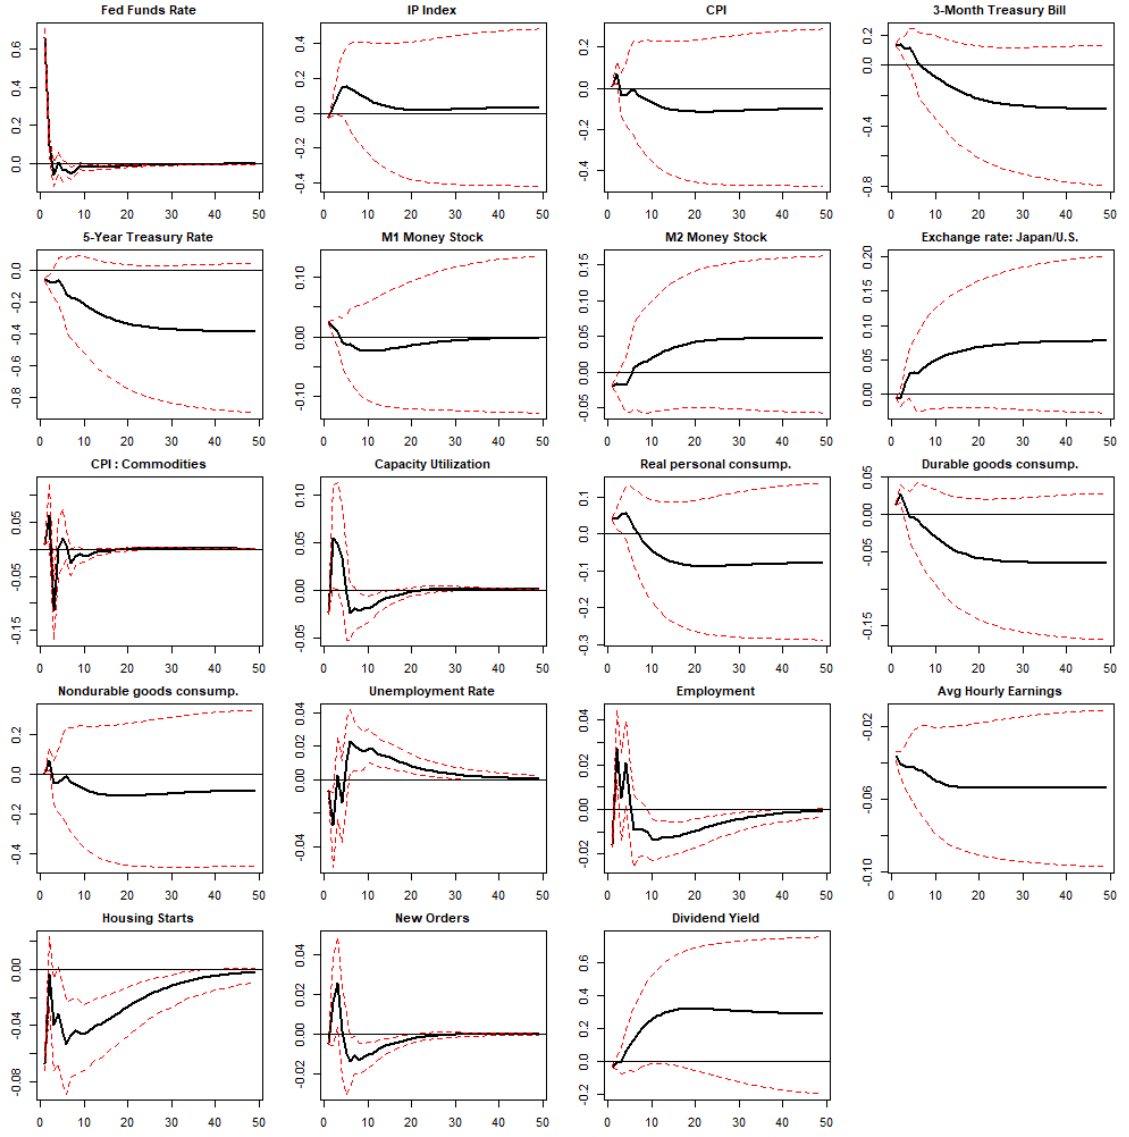


Figura 5.3: Funciones de respuesta al impulso en D^2FM



Del análisis gráfico de las funciones de respuesta al impulso para cada uno de los modelos, para el caso del modelo FAVAR en la figura 5.1 y el modelo DFM estimado por algoritmo EM en la figura 5.2 presentan movimientos de las curvas similares en para varias de las variables. También, comparando los gráficos con los presentados en Bernanke et al. (2005) para distintos factores y métodos de estimación, en la mayoría de los casos los resultados serían coincidentes. Cabe resaltar que si bien se busca replicar los resultados, las series de datos no son las mismas y probar con otras series podría conducir a resultados más satisfactorios.

Los resultados en el caso del modelo D^2FM no serían coincidentes con la teoría y con los presentados en Bernanke et al. (2005). Esto es particularmente claro para el caso de las tasas de interés, los agregados monetarios y los dividendos.

5.2.0.2. Descomposición de la varianza del error de predicción

La DV mide la fracción de la varianza del error de predicción del componente común, para un horizonte temporal dado, que se puede atribuir a un determinado shock. Los resultados de la DV surgen a partir de los coeficientes de la representación *MA* del *VAR* y de la varianza de las perturbaciones estructurales. Si se considera a la fracción de la varianza de $Y_{t+s} - \hat{Y}_{t+s}$ dada por las perturbaciones de política monetaria ε_t^{PM} , se tiene

$$\frac{var(Y_{t+s} - \hat{Y}_{t+s|t}|\varepsilon_t^{PM})}{var(Y_{t+s} - \hat{Y}_{t+s|t})} \quad (5.1)$$

Bernanke et al. (2005) plantean que un resultado típico en la literatura asociada a los *VAR* es que las perturbaciones de PM explican una fracción relativamente modesta del error de predicción de las medidas de actividad real de la economía y de la inflación. Pero, como una parte de la varianza de las variables macroeconómicas se explica por su componente idiosincrático, que puede reflejar en parte el error de medida y el punto hasta el cual los determinantes del ciclo económico no tienen ninguna influencia, no es del todo claro que la DV sea una medida precisa de la importancia relativa de los shocks estructurales. En este sentido, los modelos FAVAR permiten encontrar una versión más precisa de la DV donde la importancia relativa de una perturbación estructural es evaluada solo en relación a la porción de la variable explicada por los componentes comunes. De esta forma, la DV para X_{it} se expresa como

$$\frac{\Lambda_i var(Y_{t+s} - \hat{Y}_{t+s|t}|\varepsilon_t^{PM}) \Lambda_i^T}{\Lambda_i var(Y_{t+s} - \hat{Y}_{t+s|t}) \Lambda_i^T}$$

donde Λ_i es la i -ésima fila de $\Lambda = [\Lambda^f, \Lambda^y]$ y $\frac{var(C_{t+s} - \hat{C}_{t+s|t}|\varepsilon_t^{PM})}{var(C_{t+s} - \hat{C}_{t+s|t})}$ es la DV típica de los modelos *VAR*.

En las siguientes tablas 5.2, 5.3 y 5.4, la primer columna mide la contribución de la perturbación de de PM sobre el error de predicción de la varianza del componente común (\hat{F}_t, Y_t) en un horizonte de 60 meses. La segunda columna, contiene el R^2 del componente común (\hat{F}_t, Y_t) para cada una de las variables. La tercer columna es la multiplicación de las dos columnas anteriores y devuelve las DV de un *VAR* estándar.

Tabla 5.2: DV para FAVAR

	Variables	Contribucion	R cuadrado	DV
1	Fed Funds Rate	0.367	1.000	0.367
2	IP Index	0.046	0.891	0.041
3	CPI	0.021	0.760	0.016
4	3-Month Treasury Bill	0.064	0.623	0.040
5	5-Year Treasury Rate	0.074	0.812	0.060
6	M1 Money Stock	0.008	0.071	0.001
7	M2 Money Stock	0.006	0.067	0.000
8	Exchange rate: Japan/U.S.	0.016	0.119	0.002
9	CPI : Commodities	0.022	0.804	0.018
10	Capacity Utilization	0.048	0.838	0.040
11	Real personal consump.	0.013	0.226	0.003
12	Durable goods consump.	0.001	0.028	0.000
13	Nondurable goods consump.	0.021	0.796	0.017
14	Unemployment Rate	0.040	0.366	0.015
15	Employment	0.031	0.282	0.009
16	Avg Hourly Earnings	0.001	0.005	0.000
17	Housing Starts	0.110	0.785	0.086
18	New Orders	0.009	0.176	0.002
19	Dividend Yield	0.035	0.666	0.023

La contribución del choque de PM para el modelo FAVAR oscila entre 0.1 % y un 11 %. En particular, el choque de PM explica el 11 % de la inversión inmobiliaria (Housing Starts), un 4.6 % del índice de producción industrial (IP Index) y un 7.4 % y 6.4 % de las tasas de interés de largo plazo (5-Year Treasury Rate) y corto plazo (3-Month Treasury Bill), respectivamente. Esto sugiere un efecto muy modesto del efecto PM aunque para algunas variables no es trivial.

Si se analizan los resultados del R^2 de los componentes comunes, para varias variables los factores explican una fracción importante de las variables. Es el caso de IP Index con un 89 %, Capacity utilization con 83.8 %, y 5-Year Treasury Rate con 81.2 %. Se podría concluir que el modelo FAVAR sería capaz de capturar una dimensión importante de los movimiento asociados al ciclo de negocios. El R^2 es particularmente bajo para los salarios medidos por Avg Hourly Earnings y para el agregado monetario M1. Esto sugiere que se debe tener menos confianza en las estimaciones de respuesta al impulso para estas variables.

Los resultados de la primer columna en relación a la DV que resulta de

un VAR estándar, en la tercer columna, son notoriamente distintos para una cantidad elevada de variables. Sin embargo, para el caso del IP Index la difencia es menor e igual a 0.005.

Tabla 5.3: DV para DFM con algoritmo EM

	Variables	Contribucion	R cuadrado	DV
1	Fed Funds Rate	0.420	1.000	0.420
2	IP Index	0.059	0.932	0.055
3	CPI	0.018	0.774	0.014
4	3-Month Treasury Bill	0.079	0.469	0.037
5	5-Year Treasury Rate	0.073	0.977	0.071
6	M1 Money Stock	0.002	0.029	0.000
7	M2 Money Stock	0.004	0.033	0.000
8	Exchange rate: Japan/U.S.	0.012	0.067	0.001
9	CPI : Commodities	0.020	0.914	0.018
10	Capacity Utilization	0.065	0.986	0.064
11	Real personal consump.	0.014	0.071	0.001
12	Durable goods consump.	0.001	0.013	0.000
13	Nondurable goods consump.	0.020	0.905	0.018
14	Unemployment Rate	0.043	0.283	0.012
15	Employment	0.024	0.177	0.004
16	Avg Hourly Earnings	0.002	0.005	0.000
17	Housing Starts	0.096	0.915	0.088
18	New Orders	0.009	0.110	0.001
19	Dividend Yield	0.018	0.113	0.002

Los resultados para la contribución del choque de PM para el modelo DFM estimado por EM, son más pobres si se los compara con el primer modelo. Esto tendría sentido dado que el modelo FAVAR constituye el punto de partida del análisis y la referencia a considerar. En este contexto, la contribución del shock de PM oscila entre 0.1 % para los precios asociados a los bienes durables y 7.9 % para los intereses de corto plazo (3-Month Treasury Bill). Con este modelo los resultados indican un efecto aún más pequeño de la PM sobre las variables de interés.

A pesar de lo anterior, los resultados del R^2 de los componentes comunes indican que para varias variables, los factores explican una fracción importante de las variables.

Los resultados de la tercer columna en relación a la primera, mostrarían diferencias menores para las variables asociadas al producto y los ingresos, para la tasa de interés de largo plazo, los precios a través de los bienen no durables y la inversión inmobiliaria.

Tabla 5.4: DV para D^2FM

	Variables	Contribucion	R cuadrado	DV
1	Fed Funds Rate	0.469	1.000	0.469
2	IP Index	0.013	0.835	0.011
3	CPI	0.020	0.723	0.014
4	3-Month Treasury Bill	0.030	0.562	0.017
5	5-Year Treasury Rate	0.011	0.734	0.008
6	M1 Money Stock	0.001	0.052	0.000
7	M2 Money Stock	0.001	0.046	0.000
8	Exchange rate: Japan/U.S.	0.001	0.043	0.000
9	CPI : Commodities	0.021	0.793	0.017
10	Capacity Utilization	0.010	0.798	0.008
11	Real personal consump.	0.004	0.153	0.001
12	Durable goods consump.	0.001	0.032	0.000
13	Nondurable goods consump.	0.021	0.795	0.017
14	Unemployment Rate	0.006	0.225	0.001
15	Employment	0.005	0.163	0.001
16	Avg Hourly Earnings	0.001	0.006	0.000
17	Housing Starts	0.045	0.749	0.034
18	New Orders	0.002	0.139	0.000
19	Dividend Yield	0.015	0.562	0.008

Los resultados para el modelo D^2FM son los más pobres de los tres modelos. La contribución toma un valor máximo para el caso de la inversión inmobiliaria a través de la variable Housing Starts con apenas 4.5 % y con mínimos del 0.1 %.

En este caso también se tiene que el R^2 de los componentes comunes sería útil a la hora de explicar una fracción importante de algunas variables como es el caso del IP Index, CPI , 5-Year Treasury Rate con 83.5 %, 72.3 % y 73.4 %, respectivamente

Capítulo 6

Consideraciones finales

6.1. Conclusiones

Se examinaron tres modelos para inicialmente evaluar su rendimiento predictivo en el contexto de modelos dinámicos de factores lineales y de aprendizaje profundo. El objetivo de estos análisis es avanzar en el debate sobre la integración de modelos no lineales en las estimaciones para la implementación de políticas monetarias. Los resultados indican que, en términos de evaluación, los tres modelos presentan desempeños similares. Posteriormente, se llevó a cabo un estudio del efecto de un choque de política monetaria contractiva en diversas series de datos, las cuales están relacionadas con los objetivos de la Reserva Federal en cuanto a la estabilidad de precios, el máximo empleo posible y la demanda de bienes y servicios. En este análisis, el modelo FAVAR se destacó como el más referencial, mientras que el modelo de aprendizaje profundo mostró los resultados menos favorables.

Con lo anterior se busca arrojar luz sobre la pertinencia de ir en la dirección de modelos de cajas negras a la hora de aplicarlos en contextos socialmente sensibles como puede ser la política monetaria. Andreini et al. (2023b) establecen que su contribución del modelo D^2FM tiene como ventaja de que al ser lineal en la parte del decoder, no se pierde interpretabilidad de los resultados. Citan a Rudin (2019) que plantea dejar de emplear modelos de cajas negras¹ para la toma de decisiones que implican un alto riesgo para la sociedad. En este sentido, se cuestiona la tendencia reciente vinculada al desarrollo de modelos de Aprendizaje Automático que muchas veces dejan de ser interpretables, explicativos y transparentes para los humanos.

La discusión toma un sentido ético a la hora de seleccionar modelos que puedan impactar negativamente sobre la vida humana. Critica la idea generalizada de que existe un compromiso entre precisión e interpretabilidad. O sea, que un modelo sea más complejo no necesariamente implica que sea más preciso. Esto sería particularmente cierto cuando los datos están bien estructurados y representan correctamente cierta realidad. Se afirma que cuando se da lo anterior, tiende a haber poca diferencia en los resultados de los algoritmos. Agrega que la creencia de un compromiso entre precisión e interpretabilidad

¹Se dice que un modelo es de caja negra cuando contiene funciones complicadas de entender por los humanos, cuando son propietarios o en ambos casos. En el primer caso al menos se conocen las variables que se emplean en el mismo y sabe la forma funcional del modelo. Cuando un modelo es propietario no se tiene ni siquiera acceso para consultarlo con el fin de estudiarlo.

ha llevado a la investigación en Aprendizaje Automático a poner el foco en los modelos de aprendizaje profundo descartando modelos más interpretables. Otro argumento, a favor de los modelos interpretables, es que los modelos de cajas negras al ser explicados pueden no ser fieles a lo que calcula el modelo original. Por último, las explicaciones que se hacen de los modelos que no son fácilmente interpretables muchas veces pierden sentido.

Este estudio evidencia que tanto el modelo FAVAR como el DFM estático estimado mediante el algoritmo EM se distinguen por su transparencia e interpretabilidad inherentes. Adicionalmente, los resultados sugieren que estos modelos son más eficaces al estimar los efectos de una política monetaria diseñada para influir significativamente en la vida cotidiana de las personas. Estos hallazgos plantean una cuestión relevante para el debate académico: ¿Será realmente conveniente desviarse de un enfoque lineal en la modelización de estas dinámicas? La discusión sobre la pertinencia de adoptar modelos no lineales en este contexto queda así abierta, invitando a una reflexión crítica sobre la dirección más adecuada en la modelación de políticas monetarias.

Referencias bibliográficas

- Andreini, P., Izzo, C., y Ricco, G. (2023a). DDFM [GitHub repository]. <https://github.com/cosimoizzo/DDFM>
- Andreini, P., Izzo, C., y Ricco, G. (2023b, mayo). *Deep Dynamic Factor Models* (Working Papers). Center for Research in Economics y Statistics.
- Bai, J., y Ng, S. (2002). Determining the Number of Factors in Approximate Factor Models. *Econometrica*, 70(1), 191-221.
- Bai, J., y Ng, S. (2008). Forecasting economic time series using targeted predictors. *Journal of Econometrics*, 146(2), 304-317.
- Banbura, M., y Modugno, M. (2014). Maximum Likelihood Estimation Of Factor Models On Datasets With Arbitrary Pattern Of Missing Data. *Journal of Applied Econometrics*, 29(1), 133-160.
- Bellman, R. (1957). *Dynamic Programming* (1.^a ed.). Princeton University Press.
- Bernanke, B. S., y Boivin, J. (2003). Monetary policy in a data-rich environment. *Journal of Monetary Economics*, 50(3), 525-546.
- Bernanke, B. S., Boivin, J., y Eliasz, P. (2005). Measuring the Effects of Monetary Policy: A Factor-Augmented Vector Autoregressive (FAVAR) Approach. *The Quarterly Journal of Economics*, 120, 387-422.
- Bucacos, E. (2015). *Impact of international monetary policy in Uruguay: a FAVAR approach* (Documentos de trabajo). Banco Central del Uruguay.
- Chen, Y. B., Ng, S., y Bai, J. (2023). *fbi: Factor-Based Imputation and FRED-MD/QD Data Set* [R package version 0.7.0]. <https://github.com/cykbennie/fbi>
- Christiano, L. J., Eichenbaum, M., y Evans, C. L. (1999). Monetary policy shocks: What have we learned and to what end? En J. B. Taylor y M. Woodford (Eds.), *Handbook of Macroeconomics* (pp. 65-148, Vol. 1). Elsevier.

- Duarte, J. (2020). FAVAR BBE(2005) Replication in R [GitHub repository]. https://github.com/jbduarte/blog/tree/master/_notebooks
- Enders, W. (2014). *Applied Econometric Time Series*. Wiley.
- FED. (2018). Monetary Policy Principles and Practice [Página Web]. <https://www.federalreserve.gov/monetarypolicy/monetary-policy-principles-and-practice.htm>
- Krantz, S., y Bagdziunas, R. (2023). *dfms: Dynamic Factor Models* [R package version 0.2.1]. <https://CRAN.R-project.org/package=dfms>
- McCracken, M. W., y Ng, S. (2016). FRED-MD: A Monthly Database for Macroeconomic Research. *Journal of Business & Economic Statistics*, 34(4), 574-589.
- Moritz, S., y Bartz-Beielstein, T. (2017). imputeTS: Time Series Missing Value Imputation in R. *The R Journal*, 9(1), 207-218. <https://doi.org/10.32614/RJ-2017-009>
- Pfaff, B. (2008). VAR, SVAR and SVEC Models: Implementation Within R Package vars. *Journal of Statistical Software*, 27(4). <https://www.jstatsoft.org/v27/i04/>
- Python Software Foundation. (2023). Python Language Reference, version 3.11.6.
- R Core Team. (2023). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. Vienna, Austria. <https://www.R-project.org/>
- Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1, 206-215.
- Sheppard, K., Khrapov, S., Lipták, G., mikedeltalima, Capellini, R., alejandrocermenno, Hugle, esvhd, bot, S., Fortin, A., JPN, Judell, M., Russell, R., Li, W., 645775992, Adams, A., jbrockmendel, Migrator, L., Rabb, M., ... Çelik, B. (2023, septiembre). *bashtage/arch: Release 6.2.0* (Ver. v6.2.0). Zenodo. <https://doi.org/10.5281/zenodo.8380532>
- Shin, Y., Kwiatkowski, D., Schmidt, P., y Phillips, P. (1992). Testing the Null Hypothesis of Stationarity Against the Alternative of a Unit Root: How Sure Are We That Economic Time Series Are Nonstationary? *Journal of Econometrics*, 54(1-3), 159-178.

- Sims, C. A. (1980). Macroeconomics and Reality. *Econometrica*, 48(1), 1-48.
Consultado el 1 de diciembre de 2023, desde <http://www.jstor.org/stable/1912017>
- Stock, J., y Watson, M. (2016). Chapter 8 - Dynamic Factor Models, Factor-Augmented Vector Autoregressions, and Structural Vector Autoregressions in Macroeconomics. En J. B. Taylor y H. Uhlig (Eds.). Elsevier.

APÉNDICES

Apéndice 1

Conjunto de datos

1.1. Nombre de cada variable, su tcode, descripción y agrupación

Tabla 1.1: Conjunto de datos I

	fred	tcode	gsi:description	group
1	DPCERA3M086SBEA	5	Real Consumption	Consump.,Orders & Invent.
2	CMRMTSPLx	5	M&T sales	Consump.,Orders & Invent.
3	RETAILx	5	Retail sales	Consump.,Orders & Invent.
4	NAPM	1	PMI	Consump.,Orders & Invent.
5	NAPMNOI	1	NAPM new ordrs	Consump.,Orders & Invent.
6	NAPMSDI	1	NAPM vendor del	Consump.,Orders & Invent.
7	NAPMII	1	NAPM Invent	Consump.,Orders & Invent.
8	ACOGNO	5	Orders: cons gds	Consump.,Orders & Invent.
9	AMDMNOx	5	Orders: dble gds	Consump.,Orders & Invent.
10	ANDENOx	5	Orders: cap gds	Consump.,Orders & Invent.
11	AMDMUOx	5	Unf orders: dble	Consump.,Orders & Invent.
12	BUSINVx	5	M&T invent	Consump.,Orders & Invent.
13	ISRATIOx	2	M&T invent/sales	Consump.,Orders & Invent.
14	UMCSENTx	2	Consumer expect	Consump.,Orders & Invent.
15	HOUST	4	Starts: nonfarm	Housing
16	HOUSTNE	4	Starts: NE	Housing
17	HOUSTMW	4	Starts: MW	Housing
18	HOUSTS	4	Starts: South	Housing
19	HOUSTW	4	Starts: West	Housing
20	PERMIT	4	BP: total	Housing
21	PERMITNE	4	BP: NE	Housing
22	PERMITMW	4	BP: MW	Housing
23	PERMITS	4	BP: South	Housing
24	PERMITW	4	BP: West	Housing
25	FEDFUNDS	2	Fed Funds	Interests & Exch. Rates
26	CP3Mx	2	Comm paper	Interests & Exch. Rates
27	TB3MS	2	3 mo T-bill	Interests & Exch. Rates
28	TB6MS	2	6 mo T-bill	Interests & Exch. Rates
29	GS1	2	1 yr T-bond	Interests & Exch. Rates
30	GS5	2	5 yr T-bond	Interests & Exch. Rates
31	GS10	2	10 yr T-bond	Interests & Exch. Rates
32	AAA	2	Aaa bond	Interests & Exch. Rates
33	BAA	2	Baa bond	Interests & Exch. Rates
34	COMPAPFFx	1	CP-FF spread	Interests & Exch. Rates
35	TB3SMFFM	1	3 mo-FF spread	Interests & Exch. Rates

Tabla 1.2: Conjunto de datos II

	fred	tcode	gsi:description	group
36	TB6SMFFM	1	6 mo-FF spread	Interests & Exch. Rates
37	T1YFFM	1	1 yr-FF spread	Interests & Exch. Rates
38	T5YFFM	1	5 yr-FF spread	Interests & Exch. Rates
39	T10YFFM	1	10 yr-FF spread	Interests & Exch. Rates
40	AAAFFM	1	Aaa-FF spread	Interests & Exch. Rates
41	BAAFFM	1	Baa-FF spread	Interests & Exch. Rates
42	TWEXMMTH	5	Ex rate: avg	Interests & Exch. Rates
43	EXSZUSx	5	Ex rate: Switz	Interests & Exch. Rates
44	EXJPUSx	5	Ex rate: Japan	Interests & Exch. Rates
45	EXUSUKx	5	Ex rate: UK	Interests & Exch. Rates
46	EXCAUSx	5	EX rate: Canada	Interests & Exch. Rates
47	HWI	2	Help wanted indx	Labor Market
48	HWIURATIO	2	Help wanted/unemp	Labor Market
49	CLF16OV	5	Emp CPS total	Labor Market
50	CE16OV	5	Emp CPS nonag	Labor Market
51	UNRATE	2	U: all	Labor Market
52	UEMPMEAN	2	U: mean duration	Labor Market
53	UEMPLT5	5	U < 5 wks	Labor Market
54	UEMP5TO14	5	U 5-14 wks	Labor Market
55	UEMP15OV	5	U 15+ wks	Labor Market
56	UEMP15T26	5	U 15-26 wks	Labor Market
57	UEMP27OV	5	U 27+ wks	Labor Market
58	CLAIMSx	5	UI claims	Labor Market
59	PAYEMS	5	Emp: total	Labor Market
60	USGOOD	5	Emp: gds prod	Consump.,Orders & Invent.
61	CES1021000001	5	Emp: mining	Consump.,Orders & Invent.
62	USCONS	5	Emp: const	Consump.,Orders & Invent.
63	MANEMP	5	Emp: mfg	Consump.,Orders & Invent.
64	DMANEMP	5	Emp: dble gds	Consump.,Orders & Invent.
65	NDMANEMP	5	Emp: nondbles	Consump.,Orders & Invent.
66	SRVPRD	5	Emp: services	Consump.,Orders & Invent.
67	USTPU	5	Emp: TTU	Consump.,Orders & Invent.
68	USWTRADE	5	Emp: wholesale	Consump.,Orders & Invent.
69	USTRADE	5	Emp: retail	Consump.,Orders & Invent.
70	USFIRE	5	Emp: FIRE	Labor Market

Tabla 1.3: Conjunto de datos III

	fred	tcode	gsi:description	group
71	USGOVT	5	Emp: Govt	Labor Market
72	CES06000000007	1	Avg hrs	Labor Market
73	AWOTMAN	2	Overtime: mfg	Labor Market
74	AWHMAN	1	Avg hrs: mfg	Labor Market
75	NAPMEI	1	NAPM empl	Labor Market
76	CES06000000008	6	AHE: goods	Labor Market
77	CES20000000008	6	AHE: const	Labor Market
78	CES30000000008	6	AHE: mfg	Labor Market
79	M1SL	6	M1	Money and Credit
80	M2SL	6	M2	Money and Credit
81	M2REAL	5	M2 (real)	Money and Credit
82	AMBSL	6	MB	Money and Credit
83	TOTRESNS	6	Reserves tot	Money and Credit
84	NONBORRES	7	Reserves nonbor	Interests & Exch. Rates
85	BUSLOANS	6	C&I loan plus	Interests & Exch. Rates
86	REALLN	6	DC&I loans	Interests & Exch. Rates
87	NONREVSL	6	Cons credit	Interests & Exch. Rates
88	CONSPI	2	Inst cred/PI	Interests & Exch. Rates
89	MZMSL	6		Interests & Exch. Rates
90	DTCOLNVHFNM	6		Interests & Exch. Rates
91	DTCTHFNM	6		Interests & Exch. Rates
92	INVEST	6		Interests & Exch. Rates
93	RPI	5	PI	Interests & Exch. Rates
94	W875RX1	5	PI less transfers	Interests & Exch. Rates
95	INDPRO	5	IP: total	Interests & Exch. Rates
96	IPFPNSS	5	IP: products	Interests & Exch. Rates
97	IPFINAL	5	IP: nal prod	Interests & Exch. Rates
98	IPCONGD	5	IP: cons gds	Interests & Exch. Rates
99	IPDCONGD	5	IP: cons dble	Interests & Exch. Rates
100	IPNCONGD	5	IP: cons nondble	Interests & Exch. Rates

Tabla 1.4: Conjunto de datos IV

	fred	tcode	gsi:description	group
100	IPNCONGD	5	IP: cons nondble	Interests & Exch. Rates
101	IPBUSEQ	5	IP: bus eqpt	Interests & Exch. Rates
102	IPMAT	5	IP: matls	Interests & Exch. Rates
103	IPDMAT	5	IP: dble matls	Interests & Exch. Rates
104	IPNMAT	5	IP: nondble matls	Interests & Exch. Rates
105	IPMANSICS	5	IP: mfg	Interests & Exch. Rates
106	IPB51222s	5	IP: res util	Output and Income
107	IPFUELS	5	IP: fuels	Output and Income
108	NAPMPI	1	NAPM prodn	Output and Income
109	CUMFNS	2	Cap util	Output and Income
110	WPSFD49207	6	PPI: n gds	Prices
111	WPSFD49502	6	PPI: cons gds	Prices
112	WPSID61	6	PPI: int matls	Prices
113	WPSID62	6	PPI: crude matls	Prices
114	OILPRICE _x	6	Spot market price	Prices
115	PPICMM	6	PPI: nonferrous	Prices
116	NAPMPRI	1	NAPM com price	Prices
117	CPIAUCSL	6	CPI-U: all	Prices
118	CPIAPPSL	6	CPI-U: apparel	Prices
119	CPITRNSL	6	CPI-U: transp	Prices
120	CPIMEDSL	6	CPI-U: medical	Prices
121	CUSR0000SAC	6	CPI-U: comm.	Prices
122	CUSR0000SAD	6	CPI-U: dbles	Prices
123	CUSR0000SAS	6	CPI-U: services	Prices
124	CPIULFSL	6	CPI-U: ex food	Prices
125	CUSR0000SA0L2	6	CPI-U: ex shelter	Prices
126	CUSR0000SA0L5	6	CPI-U: ex med	Prices
127	PCEPI	6	PCE de	Prices
128	DDURRG3M086SBEA	6	PCE de : dlbes	Prices
129	DNDGRG3M086SBEA	6	PCE de : nondble	Prices
130	DSERRG3M086SBEA	6	PCE de : service	Consump.,Orders & Invent.
131	S&P 500	5	S&P 500	Stock Market
132	S&P: indust	5	S&P: indust	Stock Market
133	S&P div yield	2	S&P div yield	Stock Market
134	S&P PE ratio	5	S&P PE ratio	Stock Market
135	VXOCLS _x	1		Stock Market

1.2. Códigos de transformación de las series de datos

Siendo x_t cada variable original, se tienen las siguientes transformaciones:

$$z_t = \begin{cases} x_t & tcode = 1 \\ \Delta x_t & tcode = 2 \\ \Delta^2 x_t & tcode = 3 \\ \log(x_t) & tcode = 4 \\ \Delta \log(x_t) & tcode = 5 \\ \Delta^2 \log(x_t) & tcode = 6 \\ \Delta (x_t/x_{t-1} - 1) & tcode = 7 \end{cases}$$

Apéndice 2

Modelos VAR

2.1. Modelos VAR y SVAR

Como se explica en Stock y Watson (2016), un objetivo de la macroeconomía empírica consiste en estimar el efecto de cambios inesperados de perturbaciones estructurales sobre el resto de la economía. Si las perturbaciones, también llamadas *shocks*, fueran observables se podría estimar su efecto de manera directa. Sin embargo, como los shocks no se pueden observar, una solución consiste en identificarlos. El esquema dominante es el de Sims (1980) que emplea Vectores Autorregresivos Estructural (VARs). Los VARs buscan identificar las respuestas al impulso estructurales relativas a uno o más shocks que son combinaciones lineales de las innovaciones del VAR.

Sea Y_t un vector de tamaño $n \times 1$ de series temporales estacionarias¹. Un VAR de orden p representa a Y_t como una función lineal de sus primeros p valores rezagados más una perturbación serialmente incorrelacionada η_t . La perturbación η_t es la innovación en Y_t tiene media condicional igual a cero dados los valores pasados de Y , entonces η_t es el error de predicción un paso hacia adelante en la población bajo una pérdida de error cuadrático.

Se define el $VAR(p)$ de Y_t en su forma reducida como

$$Y_t = A_1 Y_{t-1} + \dots + A_p Y_{t-p} + \eta_t \quad A(L)Y_t = \eta_t \quad (2.1)$$

donde $A(L) = I - A_1 L - \dots - A_p L^p$ siendo L el operador de rezagos y η_t es una secuencia en diferencias martingale con matriz de covarianza Σ_η por lo que está serialmente incorrelacionada. En este esquema es necesario identificar tanto a $A(L)$ como a Σ_η . Para esto, se puede partir de la representación de medias móviles de Y_t , tal que

$$Y_t = C(L)\eta_t \quad (2.2)$$

donde $C(L) = I + C_1 L + C_2 L^2 + \dots = A(L)^{-1}$.

El SVAR, por su parte, se expresa no en términos de las innovaciones η_t sino que en relación a las perturbaciones subyacentes estructurales ϵ_t . Los shocks representan perturbaciones exógenas inesperadas sobre las relaciones económicas estructurales. En este sentido, en el SVAR se asume que las innovaciones son una combinación lineal de los shocks estructurales inobservados:

¹Se asume que tiene media cero.

$$\eta_t = H\epsilon_t \quad (2.3)$$

Se asume que los shocks están incorrelacionados

$$E\epsilon_t\epsilon_t' = \Sigma_\epsilon = \begin{pmatrix} \sigma_{\epsilon_1}^2 & & 0 \\ & \ddots & \\ 0 & & \sigma_{\epsilon_n}^2 \end{pmatrix} \quad (2.4)$$

Sustituyendo 2.3 en 2.1 y 2.2 se llega al VARS tal que

$$A(L)Y_t = H\epsilon_t \quad \text{ó} \quad B(L)Y_t = \epsilon_t \quad (2.5)$$

donde $B(L) = H^{-1}A(L)$, siempre y cuando H^{-1} exista. Cuando H^{-1} existe, se tiene que $\epsilon_t = H^{-1}\eta_t$. Con esto se puede concluir que la representación 2.5 existe y que $\Sigma_\eta = H\Sigma_\epsilon H'$.

Además, también se llega a la representación MA estructural tal que

$$Y_t = D(L)\epsilon_t \quad (2.6)$$

con $D(L) = C(L)H$

Así como la identificación de los parámetros de $A(L)$ y Σ_η se da por la proyección de Y_t en relación a sus valores presentes y pasados, los modelos 2.5 y 2.6 van a estar identificados si H y Σ_ϵ están identificados. Como consecuencia, se llega al problema de identificar al SVAR que también es un problema de identificación de los shocks estructurales.

2.2. Funciones de respuesta al impulso y Descomposición de la varianza del error de predicción

La representación MA estructural 2.6 resume el efecto causal dinámico de los shocks sobre los valores corrientes y pasados de Y_t . Y permite encontrar las FIR y la descomposición de Y_t en sus shocks estructurales. Adicionalmente, con el supuesto de que los shocks estructurales están incorrelacionados se puede calcular la FEVD.

La SIRF representa la trayectoria temporal del efecto dinámico causal en la variable Y_{it} cuando se da un aumento unitario en ϵ_{jt} en el momento 0. Si D_h es la h -ésima matriz de coeficientes de rezagos en $D(L)$, entonces $D_{h,ij}$ es el efecto causal en la i -ésima variable cuando se da un aumento unitario en el j -ésimo shock tras h períodos. Como consecuencia, $D_{h,ij}$ es el efecto sobre Y_{it+h} de un aumento unitario en ϵ_{jt} . En este sentido, la $SIRF_{ij}$ es la secuencia de los coeficientes del MA estructural,

$$SIRF_{ij} = \{D_{h,ij}\}, \quad h = 0, 1, \dots, \quad \text{donde } D_h = C_h H, \quad (2.7)$$

donde $C(L) = A(L)^{-1}$.

El efecto impacto es el efecto contemporáneo D_0 , con $D_0 = H$ porque $C_0 = I$.

Con esto se puede hallar la función de respuesta al impulso estructural acumulada que representa el efecto causal dinámico acumulado de un shock unitario sobre Y_t en el momento 0. La SIRF acumulada de un shock j sobre i tras h períodos es $\sum_{k=0}^h D_{k,ij}$.

La $FEVD_{h,ij}$ mide la importancia del j -ésimo shock para explicar la variación en Y_{it} . Se calcula la contribución relativa del shock a la varianza de los cambios inesperados en Y_{it} , h períodos hacia adelante, es decir, la varianza del error de predicción h pasos hacia adelante:

$$FEVD_{h,ij} = \frac{\sum_{k=0}^h D_{h,ij}^2 \sigma_{\epsilon_j}^2}{\text{var}(Y_{it+h}|Y_t, Y_{t-1}, \dots)} = \frac{\sum_{k=0}^h D_{h,ij}^2 \sigma_{\epsilon_j}^2}{\sum_{j=1}^n \sum_{k=0}^h D_{h,ij}^2 \sigma_{\epsilon_j}^2} \quad (2.8)$$

donde $D(L) = A(L)^{-1}H$

Apéndice 3

Estacionariedad de la series temporales

3.1. Concepto de series de tiempo estacionarias

Seguendo a Enders (2014), se dice que un proceso estocástico z_t con media y varianza finitas es estacionario en covarianza para todo t y $t - s$ cuando

$$E(z_t) = E(z_{t-s}) = \mu \quad (3.1)$$

$$\text{var}(z_t) = \text{var}(z_{t-s}) = \sigma_z^2 \quad (3.2)$$

$$\text{cov}(z_t, z_{t-s}) = \text{cov}(z_{t-j}, z_{t-j-s}) = \gamma_s \quad (3.3)$$

donde $\mu, \sigma_z^2, \gamma_s$ con constantes.

En (3.2), cuando $s = 0$ se va a tener que γ_0 es la varianza de z_t . Que una serie temporal sea estacionaria en covarianza implica que tanto la media como todas sus autocovarianzas¹ no están afectadas por cambios en los orígenes temporales².

Dado que se está en un marco de ecuaciones en diferencias, se tienen que cumplir condiciones de estabilidad en el sistema y esto implica que las raíces características asociadas al sistema de interés caigan dentro del círculo unitario. Cuando una serie temporal no sea estacionaria, es posible que presente una evidente tendencia, medias y varianzas que no son constantes en el tiempo.

3.2. Pruebas ADF

Se testea para cada serie de datos

$$H_0) \gamma = 0$$

$$H_1) \gamma \neq 0$$

En este sentido, se consideran tres ecuaciones de regresión distintas para poner a prueba H_0 ,

¹También se habla de proceso debilmente estacionario o estacionario de segundo orden.

²En modelos multivariados, el término autocovarianza refiere a la covarianza entre z_t y sus propios rezagos mientras que covarianza cruzada refiere a la covarianza entre series temporales

$$\Delta z_t = \gamma z_{t-1} + \sum_{i=2}^p \beta_i \Delta z_{t-i+1} + \varepsilon_t \quad (3.4)$$

$$\Delta z_t = a_0 + \gamma z_{t-1} + \sum_{i=2}^p \beta_i \Delta z_{t-i+1} + \varepsilon_t \quad (3.5)$$

$$\Delta z_t = a_0 + \gamma z_{t-1} + a_2 t + \sum_{i=2}^p \beta_i \Delta z_{t-i+1} + \varepsilon_t \quad (3.6)$$

Existen tres estadísticos τ , τ_μ , τ_τ para probar la hipótesis nula $H_0) \gamma = 0$ en cada caso y además, se tienen otros tres F -estadísticos ϕ_1 , ϕ_2 , ϕ_3 para hacer pruebas conjuntas sobre los coeficientes.

Los estadísticos ϕ_1 , ϕ_2 , ϕ_3 se construyen como pruebas F :

$$\phi_i = \frac{[SSR_{restringido} - SSR_{no\ restringido}] / r}{SSR_{no\ restringido} / (t - k)}$$

donde SSR es la suma de los cuadrados de los residuos en los modelos restringidos y no restringidos, r es la cantidad de restricciones, T es la cantidad de observaciones, k es la cantidad de parámetros estimados en el modelo irrestricto, $i = 1, 2, 3$. A su vez, $T - k$ van a ser los grados de libertad del modelos sin restricciones. Los valores de los coeficientes estimados se van a comparar con los valores críticos de tablas reportados por Dickey y Fuller(1981). La hipótesis nula indica que el proceso de generación de los datos es la del modelo restringido contra la hipótesis alternativa de que los datos son generados por el modelo sin restringir. Cuando los valores de ϕ_1 , ϕ_2 , ϕ_3 sean mayores a los valores críticos reportados por Dickey y Fuller(1981) se rechaza la hipótesis nula, cuando sean menores a los valores críticos entonces no se rechaza la hipótesis nula.

En el siguiente cuadro 3.1 se consideran los tres modelos y cada una de las hipótesis a testear con sus respectivos estadísticos.

Tabla 3.1: Modelos del test ADF

	Modelo	$H_0)$	Estadístico de prueba
c	$\Delta z_t = a_0 + \gamma z_{t-1} + a_2 t + \sum_{i=2}^p \beta_i \Delta z_{t-i+1} + \varepsilon_t$	$\gamma = 0$ $\gamma = a_2 = 0$ $\gamma = a_2 = a_0 = 0$	τ_τ ϕ_3 ϕ_2
b	$\Delta z_t = a_0 + \gamma z_{t-1} + \sum_{i=2}^p \beta_i \Delta z_{t-i+1} + \varepsilon_t$	$\gamma = 0$ $\gamma = a_0 = 0$	τ_μ ϕ_1
a	$\Delta z_t = \gamma z_{t-1} + \sum_{i=2}^p \beta_i \Delta z_{t-i+1} + \varepsilon_t$	$\gamma = 0$	τ

Cuando no se conozca el proceso de generación de los datos, se sugiere realizar las pruebas de Dickey-Fuller Aumentado partiendo del modelo menos restrictivo para cada serie temporal a uno más particular.

Si bien las pruebas de ADF son útiles para detectar la presencia de raíces unitarias, los mismos tienen sus limitaciones. Partiendo del modelo general al particular, cada prueba está condicionada a que las pruebas anteriores sean correctas. Cuando se empieza por el primer paso, es decir, con el modelo (c) con constante y con tendencia, se hace más difícil rechazar H_0), por lo tanto, cuando se rechaza la hipótesis nula en un modelo (c) se tiende a rechazar también la hipótesis nula cuando no se incluyan los términos deterministas. A su vez, establece que el problema principal de las pruebas de Dickey-Fuller es que tanto el intercepto como la pendiente de la tendencia son, con frecuencia, estimados de manera *pobre* bajo la presencia de raíces unitarias. En general, se tiende a no rechazar la hipótesis nula de raíz unitaria incluso cuando el verdadero valor de γ no es cero. Además, la prueba presenta limitaciones también frente a cambios de régimen.

3.3. Pruebas KPSS

En Shin et al. (1992), se parte de una representación cada serie temporal como la suma de un componente de tendencia determinística, un paseo aleatorio y un error estacionario. En este contexto, se pone a prueba

H_0) la serie es estacionaria alrededor de una tendencia

H_1) la serie es no estacionaria

que se corresponde con la hipótesis de que la varianza del paseo aleatorio (*random walk*) es igual a cero.

Se emplea un estadístico de Multiplicadores de Lagrange (ML) para testear la hipótesis nula de estacionariedad. De esta manera, siendo z_t con $t = 1, 2, \dots, T$ las series a las que se les quiere aplicar el test, se asume que se puede descomponer a la serie en la suma de un componente de tendencia determinística, un paseo aleatorio y un error estacionario se tiene que,

$$z_t = \xi t + r_t + \varepsilon_t \quad (3.7)$$

Donde r_t es un paseo aleatorio:

$$r_t = r_{t-1} + u_t, \quad (3.8)$$

donde u_t es $iid(0, \sigma_u^2)$. El valor inicial r_0 es fijo y sirve de intercepto. La hipótesis de estacionariedad es $\sigma_u^2 = 0$ y como se asume que ε_t es estacionario, bajo la hipótesis nula z_t es estacionaria alrededor de una tendencia.

En el caso particular de que en el modelo (3.7) se tenga $\xi = 0$, bajo la hipótesis nula z_t va a ser estacionaria alrededor de una constante (r_0).

Sean e_t con $t = 1, 2, \dots, T$, los residuos de la regresión z con un intercepto y tendencia. A su vez, sea $\hat{\sigma}_\varepsilon^2$ la estimación del error de la varianza de la regresión (suma de los residuos al cuadrado dividida T). Con lo anterior, se define el proceso de suma parcial de los residuos como

$$S_t = \sum_{i=1}^t r_i, \quad t = 1, \dots, T \quad (3.9)$$

Entonces el estadístico ML es

$$ML = \sum_{t=1}^T S_t^2 / \hat{\sigma}_\varepsilon^2 \quad (3.10)$$

En el caso de que se quiera poner a prueba la hipótesis nula de estacionariedad alrededor de una constante se define e_t como los residuos de la regresión z sobre un intercepto ($e_t = z_t - \bar{z}$).

Cabe resaltar que es una prueba de cola superior y se reportan los valores críticos. Además, para este caso se asume que los errores $\varepsilon_t \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma_\varepsilon^2)$. Sin embargo, se puede extender la prueba con supuestos más débiles sobre la distribución de los errores dado que el supuesto anterior puede ser poco realista.

3.4. Resultados de las pruebas ADF y KPSS

3.4.1. Resultados de las pruebas ADF

Tabla 3.2: Resultados de las pruebas ADF: modelo ct

```

-----
-----
Results for trend 'ct':
ADF Test Results:
-----

Stationary Series Count: 118
Non-Stationary Series Count: 4
-----

Stationary Series as a List:
['RPI', 'W875RX1', 'DPCERA3M086SBEA', 'CMRMTSPLx',
'RETAILx', 'INDPRO', 'IPFPNSS', 'IPFINAL', 'IPCONGD',
'IPDCONGD', 'IPNCONGD', 'IPBUSEQ', 'IPMAT',
'IPDMAT', 'IPNMAT', 'IPMANSICS', 'IPB51222S',
'IPFUELS', 'CUMFNS', 'HWI', 'HWIURATIO', 'CLF160V',
'CE160V', 'UNRATE', 'UEMPMEAN', 'UEMPLT5',
'UEMP5T014', 'UEMP150V', 'UEMP15T26', 'UEMP270V',
'CLAIMSx', 'PAYEMS', 'USGOOD', 'CES1021000001',
'USCONS', 'MANEMP', 'DMANEMP', 'NDMANEMP', 'SRVPRD',
'USTPU', 'USWTRADE', 'USTRAD', 'USFIRE', 'USGOVT',
'CES0600000007', 'AWOTMAN', 'AWHMAN', 'HOUST',
'HOUSTW', 'PERMIT', 'PERMITNE', 'PERMITS',
'PERMITW', 'AMDMNOx', 'AMDMUOx', 'BUSINVx',
'ISRATIOx', 'M1SL', 'M2SL', 'M2REAL', 'BOGMBASE',
'TOTRESNS', 'NONBORRES', 'BUSLOANS', 'REALLN',
, 'NONREVSL', 'CONSPI', 'S.P.500', 'S.P..indust',
'S.P.div.yield', 'S.P.PE.ratio', 'FEDFUNDS', 'CP3Mx',
'TB3MS', 'TB6MS', 'GS1', 'GS5', 'GS10', 'AAA', 'BAA',
'COMPAPFFx', 'TB3SMFFM', 'TB6SMFFM', 'T1YFFM',
'T5YFFM', 'T10YFFM', 'AAAFFM', 'BAAFFM', 'EXSZUSx',
, 'EXJPUSx', 'EXUSUKx', 'EXCAUSx', 'WPSFD49207',
'WPSFD49502', 'WPSID61', 'WPSID62', 'OILPRICEx',
'PPICMM', 'CPIAUCSL', 'CPIAPPSL', 'CPITRNSL', 'CPIMEDSL',
'CUSR0000SAC', 'CUSR0000SAD', 'CUSR0000SAS', 'CPIULFSL',
'CUSR0000SA0L2', 'CUSR0000SA0L5', 'PCEPI', 'DDURRG3M086SBEA',
, 'DNDGRG3M086SBEA', 'DSERRG3M086SBEA', 'CES0600000008',
'CES2000000008', 'CES3000000008', 'DTCOLNVHFM', 'DTCTHFM',
, 'INVEST']

Non-Stationary Series as a List:
['HOUSTNE', 'HOUSTMW', 'HOUSTS', 'PERMITMW']

```

Tabla 3.3: Resultados de las pruebas ADF: modelo c

Results for trend 'c':

ADF Test Results:

Stationary Series Count: 118

Non-Stationary Series Count: 4

Stationary Series as a List:

```
['RPI', 'W875RX1', 'DPCERA3M086SBEA', 'CMRMTSPLx',
'RETAILx', 'INDPRO', 'IPFPNSS', 'IPFINAL', 'IPCONGD',
, 'IPDCONGD', 'IPNCONGD', 'IPBUSEQ', 'IPMAT', 'IPDMAT',
'IPNMAT', 'IPMANSICS', 'IPB51222S', 'IPFUELS', 'CUMFNS',
, 'HWI', 'HWIURATIO', 'CLF160V', 'CE160V', 'UNRATE',
'UEMPMEAN', 'UEMPLT5', 'UEMP5T014', 'UEMP150V',
'UEMP15T26', 'UEMP270V', 'CLAIMSx', 'PAYEMS',
'USGOOD', 'CES1021000001', 'USCONS', 'MANEMP',
'DMANEMP', 'NDMANEMP', 'SRVPRD', 'USTPU',
'USWTRADE', 'USTRADe', 'USFIRE', 'USGOVT',
'CES0600000007', 'AWOTMAN', 'AWHMAN',
'HOUST', 'HOUSTS', 'HOUSTW', 'PERMIT',
'PERMITS', 'PERMITW', 'AMDMNOx', 'AMDMUOx',
'BUSINVx', 'ISRATIOx', 'M1SL', 'M2SL', 'M2REAL',
'BOGMBASE', 'TOTRESNS', 'NONBORRES', 'BUSLOANS',
'REALLN', 'NONREVSL', 'CONSPI', 'S.P.500', 'S.P..indust',
, 'S.P.div.yield', 'S.P.PE.ratio', 'FEDFUNDS', 'CP3Mx', 'TB3MS',
'TB6MS', 'GS1', 'GS5', 'GS10', 'AAA', 'BAA', 'COMPAPFFx',
'TB3SMFFM', 'TB6SMFFM', 'T1YFFM', 'T5YFFM', 'T10YFFM',
'AAAFFM', 'BAAFFM', 'EXSZUSx', 'EXJPUSx', 'EXUSUKx',
'EXCAUSx', 'WPSFD49207', 'WPSFD49502', 'WPSID61',
, 'WPSID62', 'OILPRICEx', 'PPICMM', 'CPIAUCSL', 'CPIAPPSL',
'CPITRNSL', 'CPIMEDSL', 'CUSR0000SAC', 'CUSR0000SAD',
'CUSR0000SAS', 'CPIULFSL', 'CUSR0000SA0L2', 'CUSR0000SA0L5',
'PCEPI', 'DDURRG3M086SBEA', 'DNDGRG3M086SBEA', 'DSERRG3M086SBEA',
'CES0600000008', 'CES2000000008', 'CES3000000008', 'DTCOLNVHFMN',
'DTCTHFMN', 'INVEST']
```

Non-Stationary Series as a List:

```
['HOUSTNE', 'HOUSTMW', 'PERMITNE', 'PERMITMW']
```

Tabla 3.4: Resultados de las pruebas ADF: modelo n

Results for trend 'n':

ADF Test Results:

Stationary Series Count: 109

Non-Stationary Series Count: 13

Stationary Series as a List:

['RPI', 'W875RX1', 'DPCERA3M086SBEA', 'CMRMTSPLx',
'RETAILx', 'INDPRO', 'IPFPNSS', 'IPFINAL', 'IPCONGD',
'IPDCONGD', 'IPNCONGD', 'IPBUSEQ', 'IPMAT', 'IPDMAT',
, 'IPNMAT', 'IPMANSICS', 'IPB51222S', 'IPFUELS', 'CUMFNS',
, 'HWI', 'HWIURATIO', 'CE160V', 'UNRATE', 'UEMPMEAN',
'UEMPLT5', 'UEMP5T014', 'UEMP150V', 'UEMP15T26',
'UEMP270V', 'CLAIMSx', 'PAYEMS', 'USGOOD',
'CES1021000001', 'USCONS', 'MANEMP', 'DMANEMP',
'NDMANEMP', 'SRVPRD', 'USTPU', 'USWTRADE', 'USTRADE',
'USFIRE', 'USGOVT', 'AWOTMAN', 'AMDMNOx', 'AMDMUOx',
'BUSINVx', 'ISRATIOx', 'M1SL', 'M2SL', 'M2REAL', 'BOGMBASE',
'TOTRESNS', 'NONBORRES', 'BUSLOANS', 'REALLN', 'NONREVS',
'CONSPI', 'S.P.500', 'S.P..indust', 'S.P.div.yield', 'S.P.PE.ratio',
'FEDFUNDS', 'CP3Mx', 'TB3MS', 'TB6MS', 'GS1', 'GS5', 'GS10', 'AAA',
'BAA', 'COMPAPFFx', 'TB3SMFFM', 'TB6SMFFM', 'T1YFFM', 'T5YFFM',
'T10YFFM', 'AAAFFM', 'BAAFFM', 'EXSZUSx', 'EXJPUSx', 'EXUSUKx',
'EXCAUSx', 'WPSFD49207', 'WPSFD49502', 'WPSID61', 'WPSID62',
'OILPRICEx', 'PPICMM', 'CPIAUCSL', 'CPIAPPSL', 'CPITRNSL', 'CPIMEDSL',
'CUSR0000SAC', 'CUSR0000SAD', 'CUSR0000SAS', 'CPIULFSL',
'CUSR0000SAOL2', 'CUSR0000SAOL5', 'PCEPI', 'DDURRG3M086SBEA',
'DNDGRG3M086SBEA', 'DSERRG3M086SBEA', 'CES0600000008',
'CES2000000008', 'CES3000000008', 'DTCOLNVHFM', 'DTCTHFM',
'INVEST']

Non-Stationary Series as a List:

['CLF160V', 'CES0600000007', 'AWHMAN', 'HOUST', 'HOUSTNE',
'HOUSTMW', 'HOUSTS', 'HOUSTW', 'PERMIT', 'PERMITNE',
'PERMITMW', 'PERMITS', 'PERMITW']

3.4.2. Resultados de las pruebas KPSS

Tabla 3.5: Resultados de las pruebas KPSS

```
-----  
--- TESTS KPSS ---  
-----  
Results for model=ct and nlags method=legacy:  
Count of Stationary series for model=ct and nlags method=legacy: 105  
Count of Non-Stationary series for model=ct and nlags method=legacy: 17  
-----  
Results for model=ct and nlags method=auto:  
Count of Stationary series for model=ct and nlags method=auto: 100  
Count of Non-Stationary series for model=ct and nlags method=auto: 22  
-----  
Results for model=ct and nlags method=Newey_West:  
Count of Stationary series for model=ct and nlags method=Newey_West: 100  
Count of Non-Stationary series for model=ct and nlags method=Newey_West: 22  
-----  
Results for model=ct and nlags method=Schwert:  
Count of Stationary series for model=ct and nlags method=Schwert: 102  
Count of Non-Stationary series for model=ct and nlags method=Schwert: 20  
-----  
Results for model=c and nlags method=legacy:  
Count of Stationary series for model=c and nlags method=legacy: 9  
Count of Non-Stationary series for model=c and nlags method=legacy: 31  
-----  
Results for model=c and nlags method=auto:  
Count of Stationary series for model=c and nlags method=auto: 79  
Count of Non-Stationary series for model=c and nlags method=auto: 43  
-----  
Results for model=c and nlags method=Newey_West:  
Count of Stationary series for model=c and nlags method=Newey_West: 79  
Count of Non-Stationary series for model=c and nlags method=Newey_West: 43  
-----  
Results for model=c and nlags method=Schwert:  
Count of Stationary series for model=c and nlags method=Schwert: 83  
Count of Non-Stationary series for model=c and nlags method=Schwert: 39  
-----  
-----  
Best model and lags combination with the highest stationary count:  
Model=ct, NLags=legacy, Count_stationaries=105, Count_non_stationaries=17
```

Tabla 3.6: Series en el mejor modelo KPSS

Best model and lags combination with the highest stationary count:

Model=ct, NLags=legacy, Count_stationaries=105, Count_non_stationaries=17

List of Stationary series for the best combination:

```
['RPI', 'W875RX1', 'DPCERA3M086SBEA', 'CMRMTSPLx',  
'RETAILx', 'INDPRO', 'IPFPNSS', 'IPFINAL', 'IPCONGD',  
'IPDCONGD', 'IPNCONGD', 'IPBUSEQ', 'IPMAT', 'IPDMAT',  
'IPNMAT', 'IPMANSICS', 'IPB51222S', 'IPFUELS', 'CUMFNS',  
, 'HWI', 'HWIURATIO', 'CE160V', 'UNRATE', 'UEMPMEAN',  
'UEMPLT5', 'UEMP5T014', 'UEMP150V', 'UEMP15T26',  
'UEMP270V', 'CLAIMSx', 'PAYEMS', 'USGOOD',  
'CES1021000001', 'USCONS', 'MANEMP', 'DMANEMP',  
'SRVPRD', 'USTPU', 'USWTRADE', 'USTRAD', 'USFIRE',  
'AWOTMAN', 'HOUSTNE', 'PERMITNE', 'AMDMNOx',  
'AMDMUOx', 'BUSINVx', 'ISRATIOx', 'M1SL', 'M2SL',  
'BOGMBASE', 'TOTRESNS', 'NONBORRES', 'BUSLOANS',  
'REALLN', 'NONREVSL', 'CONSPI', 'S.P.500', 'S.P..indust',  
'S.P.div.yield', 'S.P.PE.ratio', 'FEDFUNDS', 'CP3Mx', 'TB3MS',  
'TB6MS', 'GS1', 'GS5', 'GS10', 'AAA', 'BAA', 'T1YFFM', 'T5YFFM',  
'T10YFFM', 'AAAFFM', 'BAAFFM', 'EXSZUSx', 'EXJPUSx', 'EXUSUKx',  
'EXCAUSx', 'WPSFD49207', 'WPSFD49502', 'WPSID61', 'WPSID62',  
'OILPRICEx', 'PPICMM', 'CPIAUCSL', 'CPIAPPSL', 'CPITRNSL', 'CPIMEDSL',  
'CUSR0000SAC', 'CUSR0000SAD', 'CUSR0000SAS', 'CPIULFSL', 'CUSR0000SA0L2',  
'CUSR0000SA0L5', 'PCEPI', 'DDURRG3M086SBEA', 'DNDGRG3M086SBEA',  
'DSERRG3M086SBEA', 'CES06000000008', 'CES20000000008', 'CES30000000008',  
'DTCOLNVHFM', 'DTCTHFM', 'INVEST']
```

List of Non-Stationary series for the best combination:

```
['CLF160V', 'NDMANEMP', 'USGOVT', 'CES06000000007',  
'AWHMAN', 'HOUST', 'HOUSTMW', 'HOUSTS', 'HOUSTW', 'PERMIT',  
'PERMITMW', 'PERMITS', 'PERMITW', 'M2REAL', 'COMPAPFFx', 'TB3SMFFM',  
'TB6SMFFM']
```

Apéndice 4

DFM estático

4.1. Algoritmo ME

El presente algoritmo empleado en Banbura y Modugno (2014), alterna entre dos pasos: en el paso de Expectativa se completan los datos faltantes¹ en la verosimilitud, mientras que en el paso de Maximización se reoptimiza dicha expectativa.

Bajo ciertas condiciones de regularidad, el algoritmo EM converge hacia un máximo local de la verosimilitud (o un punto en su cresta).

Definiendo la log-verosimilitud conjunta de f_t con $t = 1, \dots, T$ como $l(Y, F; \theta)$ donde $Y = [y_1, \dots, y_t]$ y $F = [f_1, \dots, f_t]$, dados los datos $\Omega_T \subseteq Y$, el algoritmo se establece en dos pasos:

Primer paso: se calcula la log-verosimilitud condicional de la expectativa de los datos usando las estimaciones de iteraciones previas, $\theta(j)$:

$$L(\theta, \theta(j)) = \mathbb{E}_{\theta(j)} [l(Y, F; \theta) | \Omega_T]$$

Segundo paso: se vuelven a estimar los parámetros vía maximización de la log-verosimilitud esperada con respecto a θ :

$$\theta(j+1) = \underset{\theta}{argmax} L(\theta, \theta(j))$$

En un caso general, los factores siguen un proceso VAR estacionario de orden p tal que $f_t = A_1 f_{t-1} \dots + A_p f_{t-p} + u_t$ con $u_t \stackrel{iid}{\sim} N(0, Q)$ con A_1, \dots, A_p matrices de $r \times r$ coeficientes autorregresivos. Sin embargo, con el DFM estático planteado, se está en el caso de que $p = 1$. Si además se considera que e_t está serialmente incorrelacionado tal que $e_t \stackrel{iid}{\sim} N(0, R)$ con R diagonal, $\theta = [\Lambda, A, R, Q]$. Trás la maximización del paso 2 se va a tener como resultado las siguientes expresiones:

$$\Lambda(j+1) = \left(\sum_{t=1}^T \mathbb{E}_{\theta(j)} [y_t f_t^T | \Omega_T] \right) \left(\sum_{t=1}^T \mathbb{E}_{\theta(j)} [f_t f_t^T | \Omega_T] \right)^{-1}$$

¹En el caso de que existan datos faltantes, el algoritmo trata a la verosimilitud como si estuvieran completos.

$$A(j+1) = \left(\sum_{t=1}^{[T]} \mathbb{E}_{\theta(j)} [f_t f_{t-1}^T | \Omega_T] \right) \left(\sum_{t=1}^{[T]} \mathbb{E}_{\theta(j)} [f_t f_{t-1}^T | \Omega_T] \right)^{-1}$$

Las matrices de covarianzas en la iteración $(j+1)$ se calculan como las expectativas de la suma de los cuadrados de los residuos condicionales a las actualizaciones de las estimaciones de Λ y A :

$$R(j+1) = \text{diag} \left(\frac{1}{T} \sum_{t=1}^{[T]} \mathbb{E}_{\theta(j)} \left[(y_t - \Lambda(j+1)f_t) (y_t - \Lambda(j+1)f_t)^T | \Omega_T \right] \right) \quad (4.1)$$

$$= \text{diag} \left(\frac{1}{T} \sum_{t=1}^T \mathbb{E}_{\theta(j)} [y_t y_t^T | \Omega_T] - \Lambda(j+1) \sum_{t=1}^T \mathbb{E}_{\theta(j)} [f_t y_t^T | \Omega_T] \right) \quad (4.2)$$

y

$$Q(j+1) = \frac{1}{T} \left(\sum_{t=1}^T \mathbb{E}_{\theta(j)} [f_t f_t^T | \Omega_T] - A(j+1) \sum_{t=1}^T \mathbb{E}_{\theta(j)} [f_{t-1} f_t^T | \Omega_T] \right)$$

Como no se tienen datos faltantes en y_t entonces $\mathbb{E}_{\theta(j)} = y_t y_t^T$ y $\mathbb{E}_{\theta(j)} = [y_t f_t^T | \Omega_T] = y_t \mathbb{E}_{\theta(j)} [f_t^T | \Omega_T]$.

Por último, los momentos condicionales para los factores latentes $\mathbb{E}_{\theta(j)} = [f_t | \Omega_T]$, $\mathbb{E}_{\theta(j)} = [f_t f_t^T | \Omega_T]$, $\mathbb{E}_{\theta(j)} = [f_{t-1} f_{t-1}^T | \Omega_T]$ y $\mathbb{E}_{\theta(j)} = [f_t f_{t-1}^T | \Omega_T]$ se pueden obtener mediante un suavizador de Kalman para la representación de espacios de estados:

$$\begin{aligned} y_t &= \Lambda(j)f_t + \epsilon_t, & \epsilon_t &\stackrel{iid}{\sim} N(0, R(j)) \\ f_t &= A(j)f_{t-1} + u_t, & u_t &\stackrel{iid}{\sim} N(0, Q(j)) \end{aligned}$$

Algorithm 3 Algoritmo EM para maximización de log-verosimilitud

```
1: Inicializar  $\theta(0)$  con valores estimados
2: while no se logra la convergencia do
3:   Paso de Expectativa:
4:   Calcular la log-verosimilitud condicional:
5:      $L(\theta, \theta(j)) = \mathbb{E}_{\theta(j)}[l(Y, F; \theta) | \Omega_T]$ 
6:
7:   Paso de Maximización:
8:   Estimar los parámetros maximizando la log-verosimilitud:
9:      $\theta(j+1) = \underset{\theta}{\operatorname{argmax}} L(\theta, \theta(j))$ 
10:
11:   Actualizar  $\Lambda, A, R, Q$  usando las fórmulas dadas
12: end while
13: return  $\theta$ 
```

Apéndice 5

FAVAR

5.1. Variables macroeconómicas lentas y rápidas

Los siguientes cuadros presentan las clasificaciones de las variables macroeconómicas en rápidas y lentas por grupo de variables.

Tabla 5.1: Consumo, órdenes e inventarios

fred	description	slow1	fast0
CMRMTSPLx	Real Manu. and Trade Industries Sales	0	
RETAILx	Retail and Food Services Sales	0	
AMDMNOx	New Orders for Durable Goods	0	
AMDMUOx	Un lled Orders for Durable Goods	0	
BUSINVx	Total Business Inventories	0	
ISRATIOx	Total Business: Inventories to Sales Ratio	0	
DPCERA3M086SBEA	Real personal consumption expenditures	1	

Tabla 5.2: Vivienda

fred	description	slow1	fast0
HOUST	Housing Starts: Total New Privately Owned	0	
HOUSTNE	Housing Starts, Northeast	0	
HOUSTW	Housing Starts, West	0	
PERMIT	New Private Housing Permits (SAAR)	0	
PERMITNE	New Private Housing Permits, Northeast (SAAR)	0	
PERMITS	New Private Housing Permits, South (SAAR)	0	
PERMITW	New Private Housing Permits, West (SAAR)	0	

Tabla 5.3: Intereses y tipos de cambio

fred	description	slow1 fast0
HOUST	Housing Starts: Total New Privately Owned	0
CP3Mx	3-Month AA Financial Commercial Paper Rate	0
TB3MS	3-Month Treasury Bill:	0
TB6MS	6-Month Treasury Bill:	0
GS1	1-Year Treasury Rate	0
GS5	5-Year Treasury Rate	0
GS10	10-Year Treasury Rate	0
AAA	Moody s Seasoned Aaa Corporate Bond Yield	0
BAA	Moody s Seasoned Baa Corporate Bond Yield	0
COMPAPFFx	3-Month Commercial Paper Minus FEDFUNDS	0
TB3SMFFM	3-Month Treasury C Minus FEDFUNDS	0
TB6SMFFM	6-Month Treasury C Minus FEDFUNDS	0
T1YFFM	1-Year Treasury C Minus FEDFUNDS	0
T5YFFM	5-Year Treasury C Minus FEDFUNDS	0
T10YFFM	10-Year Treasury C Minus FEDFUNDS	0
AAAFFM	Moody s Aaa Corporate Bond Minus FEDFUNDS	0
BAAFFM	Moody s Baa Corporate Bond Minus FEDFUNDS	0
EXSZUSx	Switzerland / U.S. Foreign Exchange Rate	0
EXJPUSx	Japan / U.S. Foreign Exchange Rate	0
EXUSUKx	U.S. / U.K. Foreign Exchange Rate	0
EXCAUSx	Canada / U.S. Foreign Exchange Rate	0

Tabla 5.4: Mercado de trabajo

fred	description	slow1 fast0
HWI	Help-Wanted Index for United States	1
HWIURATIO	Ratio of Help Wanted/No. Unemployed	1
CLF16OV	Civilian Labor Force	1
CE16OV	Civilian Employment	1
UNRATE	Civilian Unemployment Rate	1
UEMPMEAN	Average Duration of Unemployment (Weeks)	1
UEMPLT5	Civilians Unemployed - Less Than 5 Weeks	1
UEMP5TO14	Civilians Unemployed for 5-14 Weeks	1
UEMP15OV	Civilians Unemployed - 15 Weeks and Over	1
UEMP15T26	Civilians Unemployed for 15-26 Weeks	1
UEMP27OV	Civilians Unemployed for 27 Weeks and Over	1
CLAIMSx	Initial Claims	1
PAYEMS	All Employees: Total nonfarm	1
USGOOD	All Employees: Goods-Producing Industries	1
CES1021000001	All Employees: Mining and Logging: Mining	1
USCONS	All Employees: Construction	1
MANEMP	All Employees: Manufacturing	1
DMANEMP	All Employees: Durable goods	1
NDMANEMP	All Employees: Nondurable goods	1
SRVPRD	All Employees: Service-Providing Industries	1
USTPU	All Employees: Trade, Transportation and Utilities	1
USWTRADE	All Employees: Wholesale Trade	1
USTRADE	All Employees: Retail Trade	1
USFIRE	All Employees: Financial Activities	1
USGOVT	All Employees: Government	1
CES0600000007	Avg Weekly Hours : Goods-Producing	1
AWOTMAN	Avg Weekly Overtime Hours : Manufacturing	1
AWHMAN	Avg Weekly Hours : Manufacturing	1
CES0600000008	Avg Hourly Earnings : Goods-Producing	1
CES2000000008	Avg Hourly Earnings : Construction	1
CES3000000008	Avg Hourly Earnings : Manufacturing	1

Tabla 5.5: Producto e ingresos

fred	description	slow1	fast0
RPI	Real Personal Income	1	
W875RX1	Real personal income ex transfer receipts	1	
INDPRO	IP Index	1	
IPFPNSS	IP: Final Products and Nonindustrial Supplies	1	
IPFINAL	IP: Final Products (Market Group)	1	
IPCONGD	IP: Consumer Goods	1	
IPDCONGD	IP: Durable Consumer Goods	1	
IPNCONGD	IP: Nondurable Consumer Goods	1	
IPBUSEQ	IP: Business Equipment	1	
IPMAT	IP: Materials	1	
IPDMAT	IP: Durable Materials	1	
IPNMAT	IP: Nondurable Materials	1	
IPMANSICS	IP: Manufacturing (SIC)	1	
IPB51222S	IP: Residential Utilities	1	
IPFUELS	IP: Fuels	1	
CUMFNS	Capacity Utilization: Manufacturing	1	

Tabla 5.6: Producto e ingresos

fred	description	slow1	fast0
WPSFD49207	PPI: Finished Goods	1	
WPSFD49502	PPI: Finished Consumer Goods	1	
WPSID61	PPI: Intermediate Materials	1	
WPSID62	PPI: Crude Materials	1	
OILPRICE _x	Crude Oil, spliced WTI and Cushing	1	
PPICMM	PPI: Metals and metal products:	1	
CPIAUCSL	CPI : All Items	1	
CPIAPPSL	CPI : Apparel	1	
CPITRNSL	CPI : Transportation	1	
CPIMEDSL	CPI : Medical Care	1	
CUSR0000SAC	CPI : Commodities	1	
CUSR0000SAD	CPI : Durables	1	
CUSR0000SAS	CPI : Services	1	
CPIULFSL	CPI : All Items Less Food	1	
CUSR0000SA0L2	CPI : All items less shelter	1	
CUSR0000SA0L5	CPI : All items less medical care	1	
PCEPI	Personal Cons. Expend.: Chain Index	1	
DDURRG3M086SBEA	Personal Cons. Exp: Durable goods	1	
DNDGRG3M086SBEA	Personal Cons. Exp: Nondurable goods	1	
DSERRG3M086SBEA	Personal Cons. Exp: Services	1	

Tabla 5.7: Dinero y crédito

fred	description	slow1	fast0
M1SL	M1 Money Stock	0	
M2SL	M2 Money Stock	0	
M2REAL	Real M2 Money Stock	0	
TOTRESNS	Total Reserves of Depository Institutions	0	
NONBORRES	Reserves Of Depository Institutions	0	
BUSLOANS	Commercial and Industrial Loans	0	
REALLN	Real Estate Loans at All Commercial Banks	0	
NONREVSL	Total Nonrevolving Credit	0	
CONSPI	Nonrevolving consumer credit to Personal Income	0	
DTCOLNVHFN	Consumer Motor Vehicle Loans Outstanding	0	
DTCTHFN	Total Consumer Loans and Leases Outstanding	0	
INVEST	Securities in Bank Credit at All Commercial Banks	0	

Tabla 5.8: Mercado de activos

fred	description	slow1	fast0
SP500	SPs Common Stock Price Index: Composite	0	
SPindust	SPs Common Stock Price Index: Industrials	0	
SPdivyield	SPs Composite Common Stock: Dividend Yield	0	
SPPERatio	SPs Composite Common Stock: Price-Earnings Ratio	0	

Apéndice 6

Análisis de FIR y ED

6.1. Variables macroeconómicas para el análisis de impacto de política monetaria

Tabla 6.1: Variables para análisis de impacto de PM

	fred	description
3	DPCERA3M086SBEA	Real personal consumption expenditures
6	INDPRO	IP Index
20	CUMFNS	Capacity Utilization: Manufacturing
24	CE16OV	Civilian Employment
25	UNRATE	Civilian Unemployment Rate
50	HOUST	Housing Starts: Total New Privately Owned
65	AMDMNOx	New Orders for Durable Goods
70	M1SL	M1 Money Stock
71	M2SL	M2 Money Stock
82	S&P div yield	S&P s Composite Common Stock: Dividend Yield
84	FEDFUNDS	Efective Federal Funds Rate
86	TB3MS	3-Month Treasury Bill:
89	GS5	5-Year Treasury Rate
103	EXJPUSx	Japan / U.S. Foreign Exchange Rate
113	CPIAUCSL	CPI : All Items
117	CUSR0000SAC	CPI : Commodities
124	DDURRG3M086SBEA	Personal Cons. Exp: Durable goods
125	DNDGRG3M086SBEA	Personal Cons. Exp: Nondurable goods
127	CES0600000008	Avg Hourly Earnings : Goods-Producing

ANEXOS

Anexo 1

Esquema de implementación

1.1. Esquema de implementación en Python y R

Figura 1.1: Esquema de implementación general

